

臺灣自編大學教科書

大模型導論

Introduction to Large Language Models

第 10 篇

多模態、具身智慧與總整專題

Multimodality, Embodied AI, and Capstone

第 38 章 多模態與視覺語言模型

第 39 章 臺語語音、低資源語言與具身智慧

第 40 章 總整專題

李世淵（機器人叫獸） 編著

助教 李天宇、李宇晴

2026 年 8 月 第一版

序言 走出文字之後

前九篇的內容都在文字裡。這一冊要走出去——先到影像，再到語音與物理世界，最後回到一個問題：你能用這四十章做出什麼。

而走出文字之後，你會發現前面建立的一切幾乎都還適用。第 3 篇的 Transformer 不需要修改，第 6 篇的適配方法完全通用，第 7 至 9 篇的檢索、評測、治理原封不動。改變的只是輸入的形式——以及成本。

三章，三個轉向

第 38 章的轉向是「看」。一張 896×896 的文件影像要花 4,096 個詞元，相當於 2,900 個繁體中文字——非文字的模態貴五到十倍，而這決定了架構：能先轉成文字的就先轉。

第 39 章的轉向是「聽」與「動」。臺語的公開標註語音約五百小時，是英語的萬分之五；而具身系統的語言模型延遲 800 毫秒，對上關節控制需要的 10 毫秒差了八十倍。兩個限制都是結構性的，不會因為模型變好而消失。

第 40 章的轉向是「交出去」。它不教新技術，而是把前三十九章整合成一個自己選題、自己完成、並且能誠實說明限制的專題。

一個貫穿本冊的觀察

本冊的三章都在處理同一件事：物理與資源的限制無法被技術繞過。

影像的詞元成本與解析度的平方成正比；臺語的資料量是英語的萬分之五；控制迴路需要 10 毫秒而語言模型要 800 毫秒。這些都不是「模型再好一點就能解決」的問題。

正確的回應不是等待技術進步，而是設計出能在限制內運作的架構——混合式的文件處理、顯示轉錄讓錯誤能被發現、規劃與控制的分層。這與第 6 篇「在兩張消費級卡上能做什麼」是同一種工程思維。

幾個值得先知道的數字

影像的詞元數與解析度的平方成正比： 224×224 為 256 個， 896×896 為 4,096 個（第 38.1.2 節）。

OCR 路線與 VLM 路線的成本差約 1.7 倍，但能力差異很大——所以混合而非二選一（第 38.2 節）。

臺語約 500 小時的標註語音，可達約 0.15 的字元錯誤率——可用但需人工校對（第 39.2.2 節）。

語言模型的 800 毫秒只夠做每秒一次的高階規劃，不能進入控制迴路（第 39.5.3 節）。

具身安全的五層防護中，最重要的三層都不依賴 AI（第 39.5.5 節）。

中型總整專題約 135 小時，其中資料與評測占 35%，系統實作只占 19%（第 40.3.1 節）。

關於最後一章

第 40 章是全書的收尾，它回到第 1 章那個講錯臺灣升學制度的模型，把那個錯誤拆解成五個環節，並對應到本書的五組方法。

而四十章的主線，可以用一句話概括：在資源有限的條件下，誠實地做出真的有用的東西。

「資源有限」是臺灣多數團隊的處境；「誠實」則是本書最堅持的一件事——不宣稱超過證據所能支持的東西。這兩件事，在技術不斷更替之後仍然成立。

關於用語

本書一律使用臺灣的專業用語與教育部標準用字。以下是本冊特別容易混淆的幾組：

本書用語	對應英文	說明與區別
視覺語言模型	VLM	能同時處理影像與文字的模型。
視覺編碼器	vision encoder	把影像轉成向量的元件。
投影層	projector	把視覺向量對齊到語言模型的空間。
影像	image	不使用「圖像」。
切片	tiling	把高解析度影像切成數塊。
重取樣	resampler	用少量查詢壓縮視覺詞元。
視覺幻覺	visual hallucination	編造影像中不存在的內容。
辨識	recognition	OCR、語音辨識。不使用「識別」指涉此義。
去識別	de-identification	個資的處理。與上一列刻意區分。
語音辨識	ASR	不使用「語音識別」。
轉錄	transcription	語音轉成文字的結果。
臺語	Taiwanese Hokkien	正式全稱為臺灣閩南語。
臺羅	Tâi-lô	臺灣閩南語羅馬字，教育部推薦。

本書用語	對應英文	說明與區別
白話字	POJ	教會傳統的羅馬字系統。
連續變調	tone sandhi	字在詞中的調與單念時不同。
腔調	accent	不使用「口音」指涉地域差異。
低資源語言	low-resource language	可用資料極少的語言。
自監督	self-supervised	不需標註的預訓練方式。
具身智慧	embodied AI	能在物理世界作動的系統。
視覺語言動作模型	VLA	再接上動作生成的架構。
致動器	actuator	執行物理動作的元件。
控制迴路	control loop	感測、決策、作動的循環。
專題	capstone project	總整的課程作品。與專案 (project) 區分。
保留集	held-out set	從未用於調校的評測資料。
交接文件	handover document	讓他人能接手的說明。

本冊有一組需要注意的區分：「辨識」 (recognition ， OCR 與語音辨識) 與「去識別」 (de-identification ， 個資的處理) ——兩者在本冊都會出現，意義完全不同。

關於臺語的用語：本書以「臺語」為主要稱呼，正式全稱為「臺灣閩南語」；書寫系統以教育部推薦的「臺羅」為內部表示 (第 39.3.2 節) 。英文專有名詞在首次出現時並列原文，其後視情況直接使用英文 (例如 VLM 、 VLA 、 ASR 、 OCR 、 patch) 。

李世淵 (機器名叫獸)

2026 年 8 月 於雲林

目 錄

序言 走出文字之後

目錄

全書架構總覽

第 38 章 多模態與視覺語言模型

Multimodality and Vision-Language Models

學習目標

38.1 視覺語言模型的架構

38.2 兩條路線：OCR 或 VLM

38.3 臺灣文件的視覺挑戰

38.4 VLM 的適配

38.5 多模態的失效模式

38.6 多模態的檢索與引用

38.7 多模態的評測

程式實作

系統案例：公文與表單的處理系統

章末評量

研究延伸與版本注意事項

常見問題

教師使用建議

附：多模態速查表

本章小結

成果檢核

第 39 章 臺語語音、低資源語言與具身智慧

Taiwanese Speech, Low-Resource Languages, and Embodied AI

學習目標

39.1 語音的表示與成本

39.2 資源的落差

39.3 臺語的特殊挑戰

39.4 語音應用的設計

39.5 視覺語言動作模型

39.6 臺灣的具身應用場景

39.7 語言保存的視角

程式實作

系統案例：臺語語音查詢或具身輔助

章末評量

研究延伸與版本注意事項

常見問題
教師使用建議
附：低資源語言與具身速查表
本章小結
成果檢核

第 40 章 總整專題

Capstone Project

學習目標

40.1 選題

40.2 整合前面的產出

40.3 工時的配置

40.4 交付清單

40.5 報告與展示

40.6 評分規準

40.7 專題之後

40.8 回到第一章

附：全書速查索引

教師使用建議

本章小結

成果檢核

索引

以下為 Word 自動目錄欄位。在 Word 中開啟後，於下方按右鍵選擇「更新功能變數」即可產生含頁碼的三層目錄；亦可使用左側導覽窗格依書籤瀏覽。

序言 走出文字之後.....	2
三章，三個轉向.....	2
一個貫穿本冊的觀察.....	2
幾個值得先知道的數字.....	2
關於最後一章.....	3
關於用語.....	3
目 錄.....	5
全書架構總覽.....	12
本冊三章的能力遞進.....	12
第 10 篇.....	14
多模態與視覺語言模型.....	15
學習目標.....	15

38.1 視覺語言模型的架構	15
38.1.1 三段架構	15
38.1.2 影像如何變成詞元	16
38.1.3 投影層的兩種設計	16
38.1.4 高解析度的切片	17
38.2 兩條路線：OCR 或 VLM	17
38.2.1 成本的對照	17
38.2.2 能力的對照	18
38.2.3 混合策略	18
38.2.4 什麼時候必須用 VLM	19
38.2.5 一個決策流程	19
38.2.6 OCR 品質的量測	20
38.3 臺灣文件的視覺挑戰	20
38.3.1 六個特殊之處	21
38.3.2 可辨識性的測試	21
38.3.3 前處理的價值	22
38.4 VLM 的適配	23
38.4.1 三種訓練策略	23
38.4.2 用 LoRA 的成本	23
38.4.3 繁中 VLM 的資料	24
38.4.4 從既有文件產生訓練資料	24
38.5 多模態的失效模式	25
38.5.1 視覺幻覺	25
38.5.2 幻覺的測試設計	25
38.5.3 解析度不足的症狀	26
38.5.4 高風險應用的界線	26
38.6 多模態的檢索與引用	27
38.6.1 三種檢索設計	27
38.6.2 位置資訊的保留	27
38.6.3 引用的呈現	28
38.7 多模態的評測	29
38.7.1 三個面向	29
38.7.2 評測集的設計	29
38.7.3 評測的成本	29
程式實作	31
程式 38A 能力探測與成本量測	31
程式 38B 混合式文件系統	31
程式 38C 多模態評測	31
系統案例：公文與表單的處理系統	32

要處理的五類文件	32
必須交付的九項	32
評分重點	33
章末評量	34
一、概念題	34
二、計算題	34
三、除錯題	34
四、系統設計題	34
五、臺灣情境與倫理題	35
評量提示（給自學者）	35
研究延伸與版本注意事項	35
常見問題	35
教師使用建議	36
附：多模態速查表	37
本章小結	37
成果檢核	38
臺語語音、低資源語言與具身智慧	39
學習目標	39
39.1 語音的表示與成本	39
39.1.1 四種表示方式	39
39.1.2 與文字的成本對照	40
39.1.3 三種架構	40
39.2 資源的落差	41
39.2.1 量級的對照	41
39.2.2 五百小時能做什麼	41
39.2.3 為什麼跨語言遷移有幫助	42
39.2.4 資料的取得	42
39.3 臺語的特殊挑戰	43
39.3.1 書寫系統的多樣性	43
39.3.2 書寫系統的處置	43
39.3.3 變調與其他語言學挑戰	44
39.3.4 評測的特殊考量	44
39.4 語音應用的設計	45
39.4.1 適合的場景	45
39.4.2 資料收集的設計	45
39.4.3 同意與倫理	45
39.4.4 錯誤傳遞的處置	46
39.4.5 長照場域的特殊考量	47
39.4.6 一個語音應用的完整設計	47

39.5 視覺語言動作模型.....	48
39.5.1 架構.....	48
39.5.2 動作的表示	49
39.5.3 延遲的硬限制	49
39.5.4 具身系統的風險分級.....	50
39.5.5 安全機制的設計.....	50
39.6 臺灣的具身應用場景	51
39.6.1 四個場域.....	51
39.6.2 語言介面的價值.....	51
39.6.3 與臺語的結合	52
39.7 語言保存的視角	52
39.7.1 技術與語言存續.....	52
39.7.2 技術能做什麼	53
39.7.3 技術做不到的	53
程式實作	55
程式 39A 語音的成本與能力量測.....	55
程式 39B 臺語資料的建置	55
程式 39C 具身系統的安全設計	56
系統案例：臺語語音查詢或具身輔助.....	56
選項 A：臺語的語音查詢.....	56
選項 B：具身系統的安全設計.....	56
兩個選項共同的交付	57
評分重點	57
章末評量	58
一、概念題.....	58
二、計算題.....	58
三、除錯題.....	58
四、系統設計題	58
五、臺灣情境與倫理題	59
評量提示（給自學者）	59
研究延伸與版本注意事項	59
常見問題	59
教師使用建議	60
附：低資源語言與具身速查表.....	61
本章小結	61
成果檢核	62
總整專題.....	63
學習目標.....	63
40.1 選題.....	63

40.1.1	三種規模.....	63
40.1.2	選題的五個判準.....	64
40.1.3	題目的類型	64
40.1.4	可行性的自我檢查	65
40.2	整合前面的產出.....	66
40.2.1	可沿用的清單	66
40.2.2	典型的組合	66
40.2.3	不必全部做的部分	67
40.2.4	一個典型專題的組裝.....	67
40.3	工時的配置.....	68
40.3.1	八個階段.....	68
40.3.2	時程的建議	69
40.3.3	常見的時程失誤.....	69
40.4	交付清單.....	70
40.4.1	必須交付的九項.....	70
40.4.2	依專題類型的調整	70
40.4.3	評測報告的最低要求.....	71
40.4.4	常見的交付缺失.....	71
40.5	報告與展示.....	72
40.5.1	書面報告的結構.....	72
40.5.2	口頭展示的設計.....	73
40.5.3	給非技術聽眾的說明.....	73
40.6	評分規準.....	74
40.6.1	六個面向.....	74
40.6.2	各面向的評分細則	74
40.6.3	不予計分的情況.....	75
40.6.4	自我檢查表	75
40.7	專題之後	76
40.7.1	三種去向.....	76
40.7.2	交給真實使用者的門檻.....	76
40.7.3	寫給後來的人	77
40.8	回到第一章.....	77
40.8.1	那個問題.....	77
40.8.2	四十章的主線	78
40.8.3	最後的話.....	79
附：	全書速查索引.....	80
	教師使用建議	81
	本章小結	81
	成果檢核.....	82

索 引.....	84
英文詞條.....	84
中文詞條.....	84

全書架構總覽

全書分為十篇四十章，另有十四組附錄。本冊為第 10 篇，也是全書的最後一冊——前兩章走出純文字，最後一章把四十章整合成一個總整專題。

篇次	章次	主題	核心產出
第 1 篇	1–4	大模型視野、數學與工程基礎	需求規格書、技術演進圖、數學速查表、可重現環境
第 2 篇	5–9	語言建模、臺灣語料與 Token 工程	基準評量規格、文本工程規格、自訓 tokenizer、語料清冊
第 3 篇	10–13	Transformer 從零實作	MiniFormosaGPT 與可生成繁體中文的模型
第 4 篇	14–17	預訓練、解碼與實驗科學	解碼工具箱、工業級訓練迴圈、實驗紀律、算力預算書
第 5 篇	18–21	算力、系統與現代架構	效能剖析、分散式決策、架構評估、臺灣算力盤點
第 6 篇	22–26	本土化後訓練與對齊	繁中適配模型、指令資料集、LoRA、偏好對齊、邊緣部署
第 7 篇	27–30	推理、知識更新與提示工程	推理工具箱、知識架構、提示規格書、RAG 系統
第 8 篇	31–34	應用系統：進階 RAG、Agent 與產品開發	多跳系統、受限 Agent、可上線的服務、場域提案
第 9 篇	35–37	部署、評測、安全與治理	服務部署規格、評測體系、紅隊報告與治理文件
第 10 篇 (本冊)	38–40	多模態、具身智慧與總整專題	視覺與語音模組、具身安全架構、總整專題

本冊三章的能力遞進

章	回答什麼問題	你會做出什麼	被誰使用
第 38 章	它能看嗎？	能力探測、混合式文件系統、幻覺測試	第 40 章
第 39 章	它能聽、能動嗎？	臺語語音方案、具身分層與安全架構	第 40 章
第 40 章	你能做出什麼？	一個自己選題、自己完成的總整專題	你自己

第 10 篇

多模態、具身智慧與總整專題

Multimodality, Embodied AI, and Capstone

第 38–40 章

本篇承諾：走出純文字。視覺、語音與具身，以及一個把四十章整合起來的總整專題。

第 38 章

多模態與視覺語言模型

Multimodality and Vision-Language Models

難度：核心 / 進階 | 建議授課：第 38 週 | 硬體需求：A 級可完成探測與評測；VLM 適配需 B 級或 LoRA

叫獸開講

一張 896×896 的高解析文件影像，要花掉 4,096 個詞元——相當於 2,900 個繁體中文字。這個數字決定了多模態應用的一切取捨：什麼時候該讓模型直接看影像、什麼時候該先做 OCR、以及一個看似簡單的「請幫我看這份文件」為什麼那麼貴。

學習目標

讀完本章並完成三個程式實作與一個系統案例後，你應該能夠：

1. 說明視覺語言模型的三段架構，並指出各段的作用。
2. 計算影像的詞元成本，並據此規劃解析度與切片策略。
3. 比較「OCR 後純文字」與「VLM 直接看影像」兩條路線的取捨。
4. 辨識臺灣文件在視覺處理上的特殊挑戰。
5. 選擇 VLM 的訓練策略，並計算各策略的成本。
6. 為多模態應用設計評測，涵蓋視覺與語言兩個面向。
7. 辨識多模態特有的失效模式，包含視覺幻覺。
8. 設計多模態的檢索與引用機制。
9. 為臺灣的實際場域選擇合適的多模態方案。

本章的定位

第 10 篇是本書的最後一篇，處理的是「文字以外」。本章談視覺、第 39 章談語音與具身，而第 40 章把四十章整合成一個總整專題。本章不會重新教一次前面的內容——第 22 至 26 章的適配、第 30 章的檢索、第 36 章的評測，在多模態上全部適用，本章只補上視覺特有的部分。

38.1 視覺語言模型的架構

38.1.1 三段架構

元件	做什麼	典型規模	章節
視覺編碼器	把影像轉成一組向量	約 0.3 B	38.1.2
投影層	把視覺向量對齊到語言模型的空間	約 0.02 B	38.1.3
語言模型	接收影像與文字的詞元並生成	3 B 至 70 B	第 3 篇

關鍵的設計是第二段：投影層讓影像變成語言模型眼中的「詞元」。經過它之後，一張圖就是一段特殊的序列，而語言模型用處理文字的同一套機制處理它。

這個設計的優雅之處在於：第 10 至 13 章實作的 Transformer 完全不需要修改。影像的向量從投影層進來，接下來的注意力、前饋、生成都一模一樣。

38.1.2 影像如何變成詞元

視覺編碼器把影像切成固定大小的小塊 (patch)，每一塊變成一個向量。

$$\text{詞元數} = (\text{影像邊長} \div \text{patch 大小})^2$$

解析度	patch 14 的網格	詞元數	相當於繁中字數
224 × 224	16 × 16	256	約 183
336 × 336	24 × 24	576	約 411
448 × 448	32 × 32	1,024	約 731
896 × 896	64 × 64	4,096	約 2,926

(繁中字數以 fertility 1.4 換算。)

這張表是本章最重要的成本依據：詞元數與解析度的平方成正比。解析度加倍，成本變四倍——而那正是多模態應用最容易失控的地方。

38.1.3 投影層的兩種設計

做法	說明	詞元數	取捨
線性投影	每個 patch 直接映射成一個詞元	等於 patch 數	簡單但詞元多
重取樣	用少量的可學查詢壓縮	固定 (例如 64)	省詞元但可能失真

第二種的價值在於把詞元數與解析度解耦：無論影像多大，都壓成固定的 64 個詞元。代價是細節的損失——對「這張圖裡有什麼」足夠，對「讀出這份文件的第三行」則不夠。

這個取捨直接對應應用類型：看圖說話用重取樣就好，讀文件必須用線性投影加高解析度。

38.1.4 高解析度的切片

視覺編碼器通常只支援固定的輸入尺寸 (例如 336×336)。要處理更高解析度的影像，常見的做法是切片。

策略	切片數	總詞元數	適用
僅縮圖	1	576	整體理解
4 切片加縮圖	5	2,880	一般文件
9 切片加縮圖	10	5,760	密集文字

(336×336、patch 14，每片 576 詞元。縮圖提供全局的脈絡。)

加上縮圖是一個關鍵的設計：只有切片的話，模型看不到各片之間的相對位置。縮圖提供了全局的版面資訊，而切片提供細節——兩者互補。

但成本上升得很快：9 切片的 5,760 詞元，已經超過多數應用的整個提示預算 (第 29.1.2 節的典型值是 5,250)。所以切片策略必須依實際需求選擇，而非一律用最高的。

38.2 兩條路線：OCR 或 VLM

38.2.1 成本的對照

對「處理一份文件」這個最常見的臺灣需求，有兩條路線。

路線	一頁的詞元數	相對成本	說明
OCR 後純文字	約 1,680	1.0×	1,200 字、fertility 1.4
VLM 直接看 (5 片)	約 2,880	1.7×	336×336 切片

成本差距沒有想像中大 (1.7 倍)，但兩者的能力差異很大。

38.2.2 能力的對照

面向	OCR 後純文字	VLM 直接看	判斷
文字內容	好 (若 OCR 準)	好	相當
版面與結構	丟失	保留	VLM 勝
表格	常錯亂	較好	VLM 勝
印章與簽名	完全丟失	可辨識	VLM 勝
手寫批註	常失敗	較好	VLM 勝
可檢索性	好 (純文字可切塊)	差	OCR 勝
引用精確位置	可以	困難	OCR 勝
大量文件	可行	成本高	OCR 勝

這張表指向一個明確的策略：兩者不是二選一，而是分工。

38.2.3 混合策略

階段	用什麼	為什麼	章節
建索引	OCR 後的文字	可切塊、可檢索、便宜	第 30.3 節
檢索	純文字的向量與 BM25	成熟且有效	第 30.2 節
需要細節時	取回原始影像給 VLM	版面、表格、印章	本節
引用	指向 OCR 文字的位置	可精確定位	第 30.5 節

這個混合策略是本章建議的預設架構：用 OCR 建索引（便宜、可檢索），只在需要時才調用 VLM（保留視覺資訊）。它同時取得兩者的優點，而成本接近純文字的方案。

第四列值得強調：引用應該指向 OCR 的文字位置，而非影像。這讓第 30.5 節的引用驗證仍然適用——你能檢查引用的內容是否真的存在。

38.2.4 什麼時候必須用 VLM

情況	為什麼 OCR 不夠	例子	章節
版面本身有意義	結構資訊丟失	公文的主旨與說明	38.3.1
表格複雜	OCR 常錯亂	成績單、財報	同上
有非文字的元素	OCR 讀不到	印章、簽名、圖表	同上
手寫內容	OCR 準確率低	簽核意見	同上
需要判斷真偽	需要視覺特徵	證件、公文	38.5.4

最後一列需要特別謹慎：用 VLM 判斷文件真偽是一個高風險的應用。它可能被偽造的影像欺騙，而錯誤的判斷有法律後果。本書的立場是：這類應用應該只提供輔助的觀察，最終判斷交給人（第 34.2.3 節）。

38.2.5 一個決策流程

把 38.2.1 到 38.2.4 節整合成一個可以照著走的判斷。

步驟	問題	若「是」	若「否」
1	有原始的電子檔嗎	直接用文字，不需視覺	進入步驟 2
2	OCR 的品質夠嗎	進入步驟 3	用 VLM 或改善前處理
3	版面或非文字元素重要嗎	混合策略	純文字即可
4	需要引用精確位置嗎	保留位置資訊	可略
5	文件量很大嗎	優先控制成本	可較寬鬆

第一步常被跳過但很重要：很多機構的文件其實有電子檔，只是流通的版本是掃描的。花點時間問清楚，可能省下整套視覺處理的成本。

第二步的「品質夠嗎」需要量測而非猜測。實務上的做法是：抽二十份文件做 OCR，人工檢查字元正確率——若超過 0.98，多數應用已經夠用。

38.2.6 OCR 品質的量測

formosa/vision/ocr_quality.py

```
def char_error_rate(hypothesis: str, reference: str) -> float:
    """字元錯誤率：編輯距離除以參考長度"""
    import numpy as np
    h, r = hypothesis, reference
    d = np.zeros((len(h) + 1, len(r) + 1), dtype=int)
    d[:, 0] = np.arange(len(h) + 1)
    d[0, :] = np.arange(len(r) + 1)
    for i in range(1, len(h) + 1):
        for j in range(1, len(r) + 1):
            cost = 0 if h[i-1] == r[j-1] else 1
            d[i, j] = min(d[i-1, j] + 1, d[i, j-1] + 1, d[i-1, j-1] + cost)
    return d[len(h), len(r)] / max(len(r), 1)

def ocr_quality_report(pairs, critical_pattern=None):
    """pairs: [(ocr_text, ground_truth), ...]"""
    import re
    cers = [char_error_rate(h, r) for h, r in pairs]

    # 關鍵數值的正確率單獨看（38.5.3 節）
    critical_pattern = critical_pattern or r"\d[\d,]*\$*元|民國\$*\d+\$*年|\d+\$*學分"
    crit_ok = crit_total = 0
    for h, r in pairs:
        truth_vals = set(re.findall(critical_pattern, r))
        ocr_vals = set(re.findall(critical_pattern, h))
        crit_total += len(truth_vals)
        crit_ok += len(truth_vals & ocr_vals)

    return {
        "n_docs": len(pairs),
        "cer_mean": round(sum(cers) / max(len(cers), 1), 4),
        "cer_worst": round(max(cers), 4) if cers else None,
        "critical_accuracy": round(crit_ok / max(crit_total, 1), 4),
        # 整體可接受但關鍵值錯誤，比整體差更危險
        "verdict": ("可用純文字路線"
                    if sum(cers)/max(len(cers),1) < 0.02
                    and crit_ok/max(crit_total,1) > 0.99
                    else "建議混合或改善前處理"),
    }
```

critical_accuracy 這個欄位是本節的重點：整體字元錯誤率 0.015 聽起來很好，但如果錯的剛好都是金額，那就完全不可用。所以關鍵數值必須單獨統計——這與第 36.2.2 節「分層報告」的原則相同。

38.3 臺灣文件的視覺挑戰

38.3.1 六個特殊之處

挑戰	出現在哪	為什麼難	章節
直書與橫書混排	公文、書籍、標語	閱讀順序不明確	本節
繁體罕用字	地名、人名	訓練資料中稀少	第 6.3 節
印章與浮水印	公文、證明文件	遮蔽文字、需辨識	38.3.2
手寫批註	簽核、審查意見	字跡差異大	同上
表格線與格線	申請書、表單	版面解析困難	同上
民國紀年	日期欄位	需正確換算	第 6.5 節

第一列是最容易被忽略的：國際模型多以橫書為主，直書的閱讀順序未必正確。一份直書的公文可能被讀成完全錯亂的順序——而模型不會告訴你它讀錯了。

第二列在視覺上有一個額外的問題：罕用字的字形在訓練資料中出現得少，模型可能認錯成形近字。而臺灣的地名（例如「壠」「埔」「崙」）與人名有許多這類字。

38.3.2 可辨識性的測試

在投入應用之前，應該先測出模型在你的文件類型上能做到什麼。

formosa/vision/capability_probe.py

```

PROBE_TASKS = [
    # 基礎：文字辨識
    {"id": "text_basic", "ask": "請逐字讀出這張圖中的所有文字。",
     "check": "與人工轉錄的字元正確率"},

    # 版面：閱讀順序
    {"id": "reading_order", "ask": "請依正確的閱讀順序列出各段落。",
     "check": "順序是否正確（直書尤其重要）"},

    # 結構：表格
    {"id": "table", "ask": "請把表格轉成 Markdown 格式。",
     "check": "行列對應是否正確"},

    # 非文字元素
    {"id": "stamp", "ask": "這份文件上有幾個印章？分別在什麼位置？",
     "check": "數量與位置"},

    # 手寫
    {"id": "handwriting", "ask": "請讀出手寫的部分。",
     "check": "字元正確率"},

```

```

# 罕用字
{"id": "rare_chars", "ask": "請讀出圖中的地名與人名。",
 "check": "罕用字是否認錯成形近字"},

# 幻覺測試：問圖中沒有的東西
{"id": "hallucination", "ask": "這份文件的核准日期是哪一天？",
 "check": "若圖中沒有此欄位，應回答「未見此欄位」",
 "note": "測試模型會不會編造"},
]

def run_capability_probe(model, images, tasks=None):
    """在你的文件類型上量出模型的實際能力"""
    tasks = tasks or PROBE_TASKS
    results = []
    for img in images:
        for t in tasks:
            out = generate_vlm(model, img, t["ask"], temperature=0.0)
            results.append({
                "image_id": img["id"],
                "doc_type": img.get("doc_type"),
                "task": t["id"],
                "output": out,
                "needs_human_check": True,    # 這些多需人工判定
            })
    return results

```

最後那個 hallucination 測試是本節最重要的：問一個影像中不存在的欄位，看模型會不會編造。這是第 23.5.2 節拒答設計在視覺上的版本，而 VLM 在這件事上通常比純文字模型更弱——38.5.1 節會展開。

38.3.3 前處理的價值

前處理	做什麼	效果	成本
去傾斜	校正掃描的角度	顯著改善辨識	低
對比增強	改善淡的影印本	中等改善	低
去除浮水印	減少干擾	中等	中
版面分割	先切出文字區塊	改善閱讀順序	中
解析度標準化	统一到模型的輸入尺寸	避免不必要的切片	低

第一列與第五列的投資報酬最高：成本極低但效果明顯。特別是去傾斜——臺灣機構的掃描件常有幾度的傾斜，而那會顯著影響文字辨識。

第五列有一個成本上的意涵：如果原始影像遠大於模型的輸入尺寸，先縮到合適的大小能避免不必要的切片（38.1.4 節）。一張 3000×4000 的照片若不處理，可能被切成十幾片。

38.4 VLM 的適配

38.4.1 三種訓練策略

第 22 至 26 章的適配方法在 VLM 上完全適用，但多了一個選擇：訓練哪幾段。

策略	可訓練參數	占比	適用
只訓投影層	0.02 B	0.6%	對齊視覺與語言
投影層加語言模型	3.02 B	91.0%	需調整語言行為
全部（含視覺編碼器）	3.32 B	100%	通常不需要

（視覺編碼器 0.3 B、投影層 0.02 B、語言模型 3 B。）

第一列是最常見也最經濟的：視覺編碼器已經學會「看」，語言模型已經學會「說」，需要訓練的只是把兩者接起來。而那只有 0.6% 的參數。

第三列通常不需要，理由是：視覺編碼器的能力相對通用。一個能辨識文字與版面的編碼器，在中文與英文文件上的差異不像語言模型那麼大。

38.4.2 用 LoRA 的成本

方案	可訓練參數	記憶體	相對
全參數（投影加 LM）	3.02 B	48.3 GB	基準
LoRA r=16（LM 的注意力）	11.0 M	6.82 GB	省 7.1 倍

（LoRA 的記憶體含凍結的完整模型 6.6 GB 加 adapter 0.18 GB。）

第 24 章的結論在這裡同樣成立：LoRA 讓 VLM 的適配在單張消費級卡上變得可行。而 VLM 的參數更多，這個效益也更明顯。

38.4.3 繁中 VLM 的資料

資料類型	要什麼	取得	章節
影像與描述配對	圖片加繁中的說明	需自建或翻譯	第 9 章
文件與轉錄配對	掃描件加正確的文字	可從既有文件產生	38.4.4
表格與結構化輸出	表格影像加 Markdown	可自建	第 29.4 節
問答配對	影像加問題加答案	需人工建置	第 23.5 節

第二列是臺灣情境中最容易取得的：如果你有文件的原始電子檔與掃描件，那就自動有了配對資料。把電子檔印出來再掃描，就能大量產生訓練樣本——而且轉錄是完全正確的。

38.4.4 從既有文件產生訓練資料

formosa/vision/synth_data.py (節錄)

```
def render_document_variants(text, layout_configs):
    """把同一份文字用多種版面渲染，產生訓練資料"""
    samples = []
    for cfg in layout_configs:
        img = render(text, font=cfg["font"], size=cfg["size"],
                     vertical=cfg["vertical"],          # 直書或橫書
                     columns=cfg["columns"])
        # 加上實務中會遇到的干擾
        if cfg.get("add_noise"):
            img = add_scan_artifacts(img,
                                     skew=cfg.get("skew", 0),
                                     blur=cfg.get("blur", 0),
                                     contrast=cfg.get("contrast", 1.0))
        if cfg.get("add_stamp"):
            img = overlay_stamp(img, position=cfg["stamp_pos"])

        samples.append({
            "image": img,
            "text": text,          # 完全正確的轉錄
            "layout": {"vertical": cfg["vertical"],
                      "columns": cfg["columns"]},
            "has_stamp": bool(cfg.get("add_stamp")),
            "synthetic": True,    # 必須標記
        })
    return samples
```

synthetic 這個標記很重要，理由與第 9.6 節相同：合成資料與真實資料的分布不同，必須能區分。一個只在合成資料上訓練與評測的模型，在真實的掃描件上表現可能差很多。

合成資料的正確用法是：用它做大量的基礎訓練，再用少量真實資料做最後的調校與評測。而評測必

須完全用真實資料——這與第 36.3 節防止污染的原則一致。

38.5 多模態的失效模式

38.5.1 視覺幻覺

純文字模型會編造事實，VLM 則會編造影像中不存在的東西——而這個問題通常更嚴重。

類型	樣子	為什麼發生	偵測
編造欄位	報告一個不存在的欄位值	依常見的文件格式推測	38.3.2 的探測
編造細節	描述沒有的物件	語言先驗壓過視覺	對照人工檢視
讀錯但很肯定	認錯字卻語氣確定	無法自我校準	第 27.5 節
忽略影像	完全依文字回答	影像的訊號較弱	空白影像測試

第二列的機制值得說明：語言模型的先驗很強。如果它學過「公文通常有發文字號」，那麼即使影像中沒有，它也可能「讀出」一個看起來合理的字號。

第四列有一個簡單但有效的測試：給一張空白或不相關的影像，問同樣的問題。如果模型仍然給出詳細的答案，那代表它根本沒在看影像。

38.5.2 幻覺的測試設計

formosa/vision/hallucination_test.py

```
def build_hallucination_tests(real_images):
    """四類視覺幻覺的測試"""
    tests = []

    # 一、問不存在的欄位
    for img in real_images:
        for field in img["absent_fields"]:
            tests.append({
                "type": "absent_field",
                "image": img["path"],
                "question": f"這份文件的{field}是什麼？",
                "correct_behavior": "回答未見此欄位",
                "failure": "給出一個具體的值",
            })

    # 二、空白影像對照
    tests.append({
        "type": "blank_image",
        "image": "tests/blank.png",
        "question": "請讀出這份文件的內容。",
        "correct_behavior": "說明影像為空白",
```

```

        "failure": "描述任何具體內容",
    })

# 三、不相關的影像
tests.append({
    "type": "mismatched_image",
    "image": "tests/landscape.jpg",
    "question": "這份公文的受文者是誰?",
    "correct_behavior": "指出這不是公文",
    "failure": "編造一個受文者",
})

# 四、部分遮蔽
for img in real_images:
    tests.append({
        "type": "occluded",
        "image": occlude_region(img["path"], img["key_field_bbox"]),
        "question": f"這份文件的{img['key_field']}是什麼?",
        "correct_behavior": "說明該處被遮蔽或無法辨識",
        "failure": "給出遮蔽前的值（代表在猜）",
    })

return tests

```

第四類的設計特別巧妙：把一個關鍵欄位遮住，看模型會不會「猜出」原本的值。如果它答對了，那不是能力好，而是它在用常見的格式推測——而那正是幻覺的來源。

38.5.3 解析度不足的症狀

症狀	成因	確認方法	處置
小字讀不出來	解析度不足	提高解析度重測	38.1.4 的切片
數字認錯	同上	對照人工轉錄	同上
整體理解對但細節錯	重取樣壓縮了細節	換線性投影	38.1.3
表格行列錯亂	版面資訊丟失	前處理的版面分割	38.3.3

第二列在臺灣的應用中風險特別高：金額、學分數、日期認錯，比整段讀錯更危險——因為它看起來完全合理。第 34.2.3 節的原則在這裡適用：涉及具體數值時，應該讓使用者能對照原圖確認。

38.5.4 高風險應用的界線

應用	風險	本書的立場	章節
文件內容的初步整理	低	適合	38.2.3
表格轉結構化資料	中	需人工覆核	第 29.4 節
金額或日期的抽取	高	必須人工確認	38.5.3
證件或文件的真偽判斷	極高	不建議自動化	第 32.3.2 節
人臉或身分的辨識	極高	涉及個資，需法遵確認	第 8.2 節

最後兩列需要特別謹慎。第四列的理由在 38.2.4 節說過；第五列則涉及個資的特種類別，在臺灣有明確的法規要求——而那必須在投入開發之前確認（第 37.7.1 節）。

本書的一般原則在這裡同樣適用：VLM 的輸出應該是「輔助的觀察」而非「判斷」。它可以說「這份文件上有三個印章，位置分別在……」，但不該說「這份文件是真的」。

38.6 多模態的檢索與引用

38.6.1 三種檢索設計

做法	索引什麼	優點	缺點
純文字索引	OCR 後的文字	成熟、可引用位置	丟失視覺資訊
影像向量索引	影像的向量	可用影像查影像	不易引用、可解釋性差
混合	文字索引加影像的連結	兩者的優點	需維護對應關係

第三種是本章建議的預設：用文字建索引，但每個片段都記錄它來自哪一頁的哪個區域。這讓檢索用成熟的文字方法（第 30 章），而需要時能取回對應的影像。

38.6.2 位置資訊的保留

`formosa/vision/doc_chunk.py`

```

from dataclasses import dataclass, field

@dataclass
class DocChunk:
    """延續第 30.3.4 節的 Chunk，加上視覺的位置資訊"""
    text: str # OCR 的結果
    doc: str
    page: int
    bbox: tuple # (x0, y0, x1, y1) 在頁面上的位置
    image_path: str # 原始頁面影像
    chunk_id: str = ""
    ocr_confidence: float = 1.0 # OCR 的信心
    has_visual_element: bool = False # 含表格、印章、圖表
    meta: dict = field(default_factory=dict)

    def needs_visual_check(self) -> bool:
        """判斷這個片段是否該調用 VLM"""
        return (self.has_visual_element
                or self.ocr_confidence < 0.85
                or self._contains_critical_value())

    def _contains_critical_value(self) -> bool:
        import re
        # 含金額、日期、學分等關鍵數值時，建議對照原圖
        return bool(re.search(
            r"\d[\d,]*\s*元|民國\s*\d+\s*年|\d+\s*學分", self.text))

    def crop_region(self):
        """取出這個片段對應的影像區域，供引用時顯示"""
        return crop(self.image_path, self.bbox)

```

`needs_visual_check` 這個方法把 38.2.3 節的混合策略變成一個自動的判斷：只有含視覺元素、OCR 信心低、或含關鍵數值的片段，才需要調用 VLM。其餘的用純文字處理即可。

`crop_region` 則支援了一個很有價值的介面功能：引用時直接顯示原始影像的對應區域。這比顯示 OCR 的文字更可信——使用者能親眼確認。

38.6.3 引用的呈現

做法	顯示什麼	可查證性	章節
純文字引用	OCR 的文字	中 (OCR 可能有誤)	第 30.5.2 節
文字加頁碼	加上頁次	中高	同上
文字加影像截圖	對應區域的原圖	最高	38.6.2

第三種是多模態應用的優勢所在：使用者能直接看到原始的文件片段，而不必信任 OCR 或模型的轉

述。這在法規、公文、契約等場景中特別有價值。

這也解決了第 30.5.1 節的一個弱點：純文字的引用無法讓使用者確認 OCR 是否正確。而顯示截圖就沒有這個問題。

38.7 多模態的評測

38.7.1 三個面向

第 36.4.1 節的三面向框架在多模態上需要擴充。

面向	測什麼	怎麼測	章節
視覺	看得到什麼	文字辨識、版面、元素	38.3.2
語言	說得對不對	第 36.4.2 節的所有項目	第 36.4.2 節
對齊	看到的與說的是否一致	幻覺測試	38.5.2

第三個面向是多模態特有的：模型可能「看得對、也說得流暢，但兩者無關」。而那只有用 38.5.2 節的幻覺測試才能偵測——特別是空白影像與遮蔽測試。

38.7.2 評測集的設計

類型	比例建議	為什麼	章節
一般辨識	40%	基礎能力	38.3.2
版面與結構	20%	臺灣文件的特殊性	38.3.1
關鍵數值	15%	風險最高	38.5.3
幻覺測試	15%	最容易被忽略	38.5.2
拒答（不該答）	10%	延續第 36.4.5 節	第 36.4.5 節

第四列的 15% 是刻意的：多模態的幻覺比純文字更難察覺（因為使用者也要看圖才能確認），所以測試的比例應該更高。

38.7.3 評測的成本

多模態評測有一個實務上的困難：多數項目必須人工判定。

項目	能自動嗎	為什麼	章節
文字辨識	可以（有標準轉錄時）	字元比對	38.3.2
表格結構	部分	可比對結構但需容錯	同上
版面順序	部分	需標註正確順序	同上
幻覺	部分	「不該答」的可自動判	38.5.2
整體正確性	不行	需人工看圖	第 36.5.1 節

第一列的括號很重要：如果你有原始的電子檔，那標準轉錄是免費的（38.4.4 節的做法）。這讓文字辨識的評測可以大規模自動化——而那是多模態評測中最容易做到規模的部分。

程式實作

本章三個實作把視覺能力整合進第 8 篇建立的系統。

程式 38A 能力探測與成本量測

項目	要做什麼	驗收標準	節次
詞元成本	不同解析度與切片的實測	與 38.1.2 節相符	38.1.2
能力探測	七類任務 (38.3.2 節)	在你的文件類型上	38.3.2
直書測試	閱讀順序的正確率	這是臺灣特有的	38.3.1
罕用字測試	地名人名辨識	含形近字的混淆	同上
前處理的效益	去傾斜前後的對照	量化改善	38.3.3
成本對照	OCR 路線 vs VLM 路線	含品質的差異	38.2

關於第三項

直書的閱讀順序是一個容易被忽略但影響巨大的問題。準備幾份真實的直書文件（公文、傳統書籍的掃描），測試模型是否能正確排序——你可能會發現它讀成了完全錯亂的順序，而輸出看起來仍然通順。

程式 38B 混合式文件系統

目標：實作 38.2.3 節的混合架構，整合進第 30 章的 RAG。

必須完成的六項：

- OCR 建索引：含位置資訊 (38.6.2 節的 DocChunk)。
- 視覺檢查的判斷：needs_visual_check 的實作與觸發率統計。
- VLM 的調用：只在必要時，並記錄成本。
- 引用含影像截圖：使用者能對照原圖。
- 成本對照：混合架構 vs 全部用 VLM。
- 品質對照：兩者在關鍵數值上的正確率。

第五項與第六項一起看才有意義：混合架構的價值在於「用少得多的成本達到接近的品質」。若品質差距很大，那個節省就不划算——而那必須用資料判斷。

程式 38C 多模態評測

項目	要建立什麼	驗收	節次
評測集	五類，依 38.7.2 節的比例	至少 100 題	38.7.2
幻覺測試	四類 (38.5.2 節)	含遮蔽測試	38.5.2
自動評分	文字辨識與結構	用電子檔產生標準答案	38.7.3
人工評分	整體正確性	含規準與 κ	第 36.5 節
成本記錄	每題的詞元數	對照 38.1.2 節	38.1.2
報告	三面向分開	含區間與 caveats	第 36.2.3 節

延伸挑戰：用空白影像跑一次完整的評測集。理想的模型應該在所有題目上都回答「影像中沒有相關內容」；而實際上你可能會發現它仍然答對了一部分——那些題目是靠語言先驗猜的，而它們在真實使用中同樣不可信。

系統案例：公文與表單的處理系統

本章的系統案例是把視覺能力加進第 8 篇的系統，處理一類臺灣機構最常見的需求。

要處理的五類文件

文件	特殊挑戰	需要 VLM 嗎	章節
公文 (電子檔)	無	否，直接用文字	38.2.3
公文 (掃描件)	印章、簽核	部分	同上
申請表單	表格、手寫	是	38.2.4
成績單	表格結構、數值	是，且需人工確認	38.5.3
證明文件	格式驗證	謹慎，不做真偽判斷	38.5.4

必須交付的九項

1. 能力探測報告 (程式 38A)：七類任務在五類文件上的結果。
2. 直書與罕用字的專門測試。

3. 成本量測：各解析度與切片策略的詞元數。
4. 混合式系統（程式 38B）：OCR 索引加選擇性的 VLM 調用。
5. `needs_visual_check` 的觸發率與正確性。
6. 引用含影像截圖的介面。
7. 成本與品質的對照：混合 vs 全 VLM。
8. 多模態評測（程式 38C）：五類、含幻覺測試。
9. 高風險界線的說明：哪些不做、為什麼。

評分重點

- 是否量測了直書的閱讀順序——這是臺灣文件的特殊挑戰。
- 幻覺測試是否包含遮蔽與空白影像。
- 關鍵數值（金額、日期、學分）是否要求人工確認。
- 混合架構的成本節省是否量化，且品質差距可接受。
- 引用是否能顯示原圖區域。
- 是否明確拒絕高風險的應用（真偽判斷、身分辨識）並說明理由。

第六項延續第 34 章與第 37 章的立場：能說出「這個我們不做」比什麼都做更專業。特別是在涉及法規或個資的應用上，那個判斷應該在提案階段就明確做出。

章末評量

一、概念題

1. VLM 的三段架構是什麼？投影層的作用為何？
2. 為什麼說「第 10 至 13 章的 Transformer 完全不需要修改」？
3. 線性投影與重取樣的取舍是什麼？各適合什麼應用？
4. 高解析度切片時為什麼要加上縮圖？
5. 「OCR 後純文字」與「VLM 直接看」各有什麼優缺點？
6. 為什麼本書建議混合策略而非二選一？
7. 臺灣文件有哪六個視覺處理上的特殊挑戰？
8. 什麼是視覺幻覺？空白影像測試能偵測什麼？
9. 為什麼「遮蔽測試中答對」可能是壞消息？

二、計算題

1. 影像 448×448 、patch 大小 14。計算 patch 詞元數。
2. 承上題，若解析度提高到 896×896 呢？成本變成幾倍？
3. 336×336 、patch 14。計算「4 切片加縮圖」的總詞元數。
4. 一頁公文約 1,200 字、fertility 1.4。計算 OCR 路線的詞元數，並與上題的 VLM 路線比較。
5. 視覺編碼器 0.3 B、投影層 0.02 B、語言模型 3 B。「只訓投影層」的可訓練參數占比是多少？
6. 承上題，全參數訓練（投影加 LM）的混合精度記憶體是多少？

三、除錯題

1. 模型讀一份直書的公文，內容都對但順序完全錯亂。請說明原因與處置。
2. 模型能正確描述文件的大致內容，但金額總是讀錯。請列出兩個可能原因。
3. 給模型一張空白影像，它仍然詳細描述了「文件內容」。請說明這代表什麼。
4. 同一份文件，模型在遮住日期欄位後仍然答出了正確的日期。請說明這是好消息還是壞消息。
5. 多模態系統的成本遠超預期。請列出三個可能原因。
6. 模型在合成的訓練資料上表現很好，但在真實掃描件上很差。請說明可能的原因。

四、系統設計題

1. 你要為一個「歷史檔案數位化」的專案設計方案。檔案是直書、有手寫批註、部分字跡模糊、且量很大（數萬頁）。請設計架構與成本控制方案。

2. 你的系統需要處理使用者上傳的證明文件。請設計：哪些資訊可以自動抽取、哪些必須人工確認、以及如何處理個資與真偽的問題。

五、臺灣情境與倫理題

1. 多模態系統可能被用於處理含個資的文件（身分證、成績單、病歷）。請討論：在臺灣的法規環境下需要注意什麼？技術上該如何降低風險？
2. 一個能讀取手寫批註的系統，可能讓原本只有少數人看得到的簽核意見變得可搜尋。請討論這帶來的機會與風險。

評量提示（給自學者）

- 計算題第 1 題： $(448/14)^2 = 32^2 = 1,024$ 個詞元。
- 計算題第 2 題： $(896/14)^2 = 64^2 = 4,096$ ；為 1,024 的 4 倍（解析度加倍、成本四倍）。
- 計算題第 3 題：每片 $(336/14)^2 = 576$ ；4 片加縮圖共 5 份 = 2,880 詞元。
- 計算題第 4 題： $1,200 \times 1.4 = 1,680$ 詞元；VLM 路線為其 $2,880/1,680 \approx 1.7$ 倍。
- 計算題第 5 題： $0.02/(0.3+0.02+3) = 0.02/3.32 \approx 0.6\%$ 。
- 計算題第 6 題： $3.02 \times 10^9 \times 16 \text{ bytes} \approx 48.3 \text{ GB}$ 。
- 除錯題第 4 題：壞消息。它代表模型在用常見的格式推測而非真的讀取（38.5.2 節第四類）。

研究延伸與版本注意事項

- 視覺語言模型的架構演進：從早期的雙塔到現在的投影式架構。
- 高解析度的處理策略：切片、動態解析度、以及原生高解析的編碼器。
- 視覺幻覺的研究：成因分析與偵測方法，是一個活躍的方向。
- 文件理解的專門模型：針對版面、表格、手寫的方法。
- 中文文件的視覺處理：直書、罕用字、印章的相關研究。
- 多模態的評測基準：設計思路值得參考並在地化。
- 本章的原理（詞元成本、混合架構、幻覺測試）穩定，但 VLM 的能力進展極快。所有能力的判斷都必須在你的文件類型上重測——而那正是程式 38A 的用途。

常見問題

問：我該用 OCR 還是 VLM？答：多數情況下兩者都要（38.2.3 節）。用 OCR 建索引（便宜、可檢索、可引用位置），只在需要視覺資訊時才調用 VLM。程式 38B 的 `needs_visual_check` 就是這個判

斷的實作。

問：解析度該設多高？答：從能滿足需求的最低開始。程式 38A 的做法是：用不同的解析度跑同一組測試，找出「再提高也不會更準」的那一點。多數應用不需要最高的解析度，而那個差別在成本上是四倍。

問：VLM 的幻覺比純文字嚴重嗎？答：通常是，而且更難察覺——因為使用者也要看圖才能確認。所以 38.7.2 節建議幻覺測試占評測集的 15%，比純文字的評測更高。

問：可以用合成資料訓練嗎？答：可以，而且對文件類的任務特別有效（38.4.4 節）。但必須標記為合成，且評測必須完全用真實資料——否則你量到的是「在合成分布上的表現」，而那與實際使用無關。

教師使用建議

本章排在第 38 週，是第 10 篇的第一章，建議 2 小時講授加 1 小時實驗。本章的示範效果很好，因為結果可以直接看到。

時段	內容	互動設計	注意事項
前 25 分鐘	38.1 至 38.2 節，架構與成本	算不同解析度的詞元數	平方關係很有感
中間 25 分鐘	38.3 節，臺灣文件的挑戰	現場測一份直書公文	順序錯亂很震撼
後 25 分鐘	38.5 節，幻覺	示範空白影像測試	效果極佳
最後 25 分鐘	38.6 至 38.7 節，檢索與評測	設計混合架構	連結到專題
實驗課 1 小時	程式 38A	各組測自己領域的文件	直書與罕用字必測

一個效果極佳的示範：給模型一張空白影像，問「這份公文的受文者是誰」。多數模型會編造一個看起來完全合理的答案——而那個畫面比任何說明都能傳達視覺幻覺的風險。

另一個建議：找一份真實的直書公文（或傳統書籍的掃描），讓模型讀出來。學生會看到內容都對但順序完全錯亂，而輸出讀起來仍然通順——那正是最危險的失敗形式。

高中授課的調整：38.1 用「把圖切成小方塊」講 patch，詞元數的平方關係是好的數學練習；38.2 完整教（兩條路線的取舍很直觀）；38.3 完整教並做直書的示範——這對高中生很有啟發性；38.5 做空白影像的示範，這是很好的批判思考訓練；38.6、38.7 挑重點。

附：多模態速查表

把本章的公式與判準整理成一張表。

要算什麼	公式或判準	典型結果	節次
影像詞元數	$(\text{邊長} \div \text{patch})^2$	336/14 為 576	38.1.2
解析度的成本	與邊長的平方成正比	加倍則四倍	同上
切片總詞元	每片詞元 $\times$ (切片數 + 1)	4 片加縮圖為 2,880	38.1.4
等效繁中字數	詞元數 $\div$ 1.4	4,096 詞元約 2,900 字	38.1.2
OCR 路線成本	字數 $\times$ fertility	1,200 字為 1,680	38.2.1
兩路線的比值	VLM $\div$ OCR	約 1.7 倍	同上
只訓投影層的占比	投影 $\div$ 總參數	約 0.6%	38.4.1
LoRA 的記憶體	底模 2 bytes + adapter	3B VLM 約 6.8 GB	38.4.2
OCR 可用的門檻	CER < 0.02 且關鍵值 > 0.99	兩者都要	38.2.6
幻覺測試的比例	評測集的 15%	高於純文字	38.7.2

使用這張表的三個提醒。第一，解析度的成本是平方關係——這是多模態最容易失控的地方。第二，OCR 的可用性要看兩個門檻，整體錯誤率低但關鍵值錯誤仍不可用。第三，幻覺測試的比例應高於純文字，因為視覺幻覺更難察覺。

本章小結

1. VLM 的三段架構是視覺編碼器、投影層、語言模型；投影層讓影像變成語言模型眼中的詞元。
2. 因為投影層的設計，第 3 篇實作的 Transformer 完全不需要修改。
3. 詞元數與解析度的平方成正比：224×224 為 256 個，896×896 為 4,096 個。
4. 一張 896×896 的影像相當於約 2,900 個繁體中文字。
5. 線性投影保留細節但詞元多；重取樣把詞元數與解析度解耦但可能失真。
6. 高解析度切片必須加上縮圖，否則模型看不到各片之間的相對位置。
7. OCR 路線與 VLM 路線的成本差約 1.7 倍，但能力差異很大。
8. 本書建議混合策略：用 OCR 建索引，只在需要時調用 VLM。

9. 引用應指向 OCR 的文字位置，讓第 30 章的驗證機制仍然適用。
10. 臺灣文件的六個挑戰：直書混排、繁體罕用字、印章、手寫、表格線、民國紀年。
11. 直書的閱讀順序是最容易被忽略的問題——輸出看起來通順但順序全錯。
12. 去傾斜與解析度標準化的投資報酬最高：成本極低但效果明顯。
13. 「只訓投影層」只有 0.6% 的參數，是最經濟的適配策略。
14. LoRA 讓 VLM 的適配從 48.3 GB 降到 6.82 GB (省 7.1 倍) 。
15. 有電子檔與掃描件的配對時，訓練資料的轉錄是完全正確且免費的。
16. 視覺幻覺比純文字更嚴重也更難察覺；空白影像與遮蔽測試是有效的偵測。
17. 「遮住欄位後仍答對」是壞消息——它代表模型在用格式推測而非讀取。
18. 關鍵數值 (金額、日期、學分) 認錯比整段讀錯更危險，必須人工確認。
19. 證件真偽判斷與身分辨識是高風險應用，本書不建議自動化。
20. 多模態評測需加上「對齊」面向：看到的與說的是否一致。

成果檢核

完成本章後你必須繳交：

- 能力探測報告 (程式 38A)：七類任務、五類文件、含直書與罕用字。
- 成本量測：各解析度與切片策略的詞元數實測。
- 前處理的效益：去傾斜與標準化前後的對照。
- 混合式系統 (程式 38B)：OCR 索引、選擇性的 VLM 調用、影像截圖的引用。
- 成本與品質的對照：混合 vs 全 VLM。
- 多模態評測 (程式 38C)：五類、含四種幻覺測試。
- 空白影像的完整評測：模型在沒有影像時能「答對」多少。
- 高風險界線的說明：哪些不做與理由。

本章讓系統能看見。但看見之後還有一件事——臺灣有很多資訊不在文字裡，也不在影像裡，而在人們說的話裡。

第 39 章要處理的是語音，特別是臺語與客語這些在數位世界中資源極度稀缺的語言。而那也是本書開頭那個問題的另一面：如果連模型都不會說我們的語言，那些語言在數位時代會發生什麼。

第 39 章

臺語語音、低資源語言與具身智慧

Taiwanese Speech, Low-Resource Languages, and Embodied AI

難度：核心 / 進階 | 建議授課：第 39 週 | 硬體需求：A 級可完成語音路線；具身路線需實體設備

叫獸開講

臺語的公開標註語音大約五百小時，而英語有一百萬小時——比例是萬分之五。這一章要處理的，是在這樣的資源條件下能做什麼、做不到什麼，以及一個比技術更根本的問題：如果連模型都不會說我們的語言，那些語言在數位時代會發生什麼。

學習目標

讀完本章並完成三個程式實作與一個系統案例後，你應該能夠：

1. 計算語音的詞元成本，並比較不同表示方式的取捨。
2. 說明臺語書寫系統的多樣性，以及它對資料建置的影響。
3. 評估低資源語言在不同資料量下的可達水準。
4. 設計臺語語音應用的資料收集與標註流程。
5. 辨識語音應用特有的失效模式與倫理議題。
6. 說明視覺語言動作模型的架構與延遲限制。
7. 為具身系統設計風險分級與安全界線。
8. 判斷語言模型在控制迴路中的合理位置。
9. 為臺灣的實際場域選擇合適的語音或具身方案。

本章的兩個主題

語音與具身看似不相關，但它們有一個共同的結構：都是把語言模型接到「非文字」的世界，而且都受到嚴格的物理限制（語音的即時性、具身的控制頻率）。本章把它們放在一起，是因為它們的工程取捨有共通的邏輯——而那個邏輯與前面九篇一脈相承。

39.1 語音的表示與成本

39.1.1 四種表示方式

表示	每秒的單位數	一分鐘的量	說明
原始波形 (16 kHz)	16,000	96 萬	模型無法直接處理
梅爾頻譜 (10 ms)	100	6,000	傳統的前端
語音編碼器 (20 ms)	50	3,000	常見的做法
離散語音單元 (40 ms)	25	1,500	最省但資訊損失多

第三列是目前最常見的：每 20 毫秒一個向量，經過投影層進入語言模型——與第 38.1.1 節的視覺架構完全同構。

39.1.2 與文字的成本對照

中文的語速約每分鐘 200 至 250 字。以 225 字計算：

形式	一分鐘的詞元數	相對	說明
文字 (轉錄後)	約 315	1.0×	225 字、fertility 1.4
語音 (20 ms)	3,000	9.5×	直接餵語音
語音 (40 ms 離散)	1,500	4.8×	壓縮後

語音的成本是文字的五到十倍——這與第 38 章視覺的結論相同：非文字的模態都很貴。而這導出同樣的架構建議：能先轉成文字的，就先轉。

39.1.3 三種架構

架構	做法	優點	缺點
管線式	ASR 轉文字，再送 LLM	便宜、可檢索、模組可替換	ASR 的錯誤會傳遞
端到端	語音直接進 LLM	保留語氣、口音、情緒	貴、資料需求大
混合	轉文字為主，保留語音特徵	兼顧	複雜度較高

對臺灣的多數應用，管線式是務實的起點。理由與第 38.2.3 節相同：轉成文字後，第 30 章的檢索、第 29 章的提示、第 36 章的評測全部可以沿用。

但管線式有一個結構性的弱點：ASR 的錯誤會無聲地傳遞下去。而在臺語這種高錯誤率的情境（39.3.3 節），那個影響可能很大——39.4.4 節會處理。

39.2 資源的落差

39.2.1 量級的對照

語言	公開標註語音（量級）	相對英語	備註
英語	約 100 萬小時	100%	—
華語（普通話）	約 5 萬小時	5.000%	—
臺灣華語	約 5,000 小時	0.500%	含在地口音
臺語	約 500 小時	0.050%	公開可用者
客語	約 100 小時	0.010%	更少
原住民族語	約 10 小時	0.001%	各族語各自更少

（量級為概略估計，實際可用量依授權與品質而異，且持續變動。）

這張表是本章的核心事實：臺語的資源約為英語的萬分之五，而原住民族語再少兩個數量級。任何技術方案都必須從這個現實出發。

39.2.2 五百小時能做什麼

資料量	預期字元錯誤率	可用性	適用
10 小時	約 0.45	不可用	概念驗證
50 小時	約 0.28	勉強	受限的場景
100 小時	約 0.22	有限	固定用語的場景
500 小時	約 0.15	可用但需人工校對	一般應用

資料量	預期字元錯誤率	可用性	適用
1,000 小時	約 0.12	較好	—

(示意值。實際表現高度依賴領域、口音、錄音品質與模型的預訓練。)

對照組是：華語的 ASR 在充足資料下可達字元錯誤率 0.05 以下。所以臺語應用的設計必須假設「每七個字會錯一個」，而那對應用架構有直接的意涵——39.4.4 節會展開。

39.2.3 為什麼跨語言遷移有幫助

做法	為什麼有效	限制	章節
多語預訓練的模型	語音的聲學特徵有共通性	對聲調語言仍有落差	第 22 章
從華語適配	共享部分詞彙與句法	音韻系統不同	同上
多方言聯合訓練	資料量加總	需處理標記	本節
自監督預訓練	不需標註，只需語音	本地語音較易取得	39.2.4

第四列是低資源語言最重要的槓桿：未標註的語音比標註的容易取得數十倍。廣播、訪談、口述歷史、家庭錄音——這些都能用於自監督的預訓練，而不需要逐字轉錄。

這也對應第 22 章的適配框架：先用大量未標註的語音學習聲學表示，再用少量標註資料做微調。而那個「少量」正是臺語現在的處境。

39.2.4 資料的取得

來源	取得難度	授權	注意事項
公開的語料庫	低	需確認	可能已被用於訓練 (第 36.3 節)
廣播與影視	中	複雜	著作權 (第 8.3 節)
口述歷史與訪談	中	需同意	倫理審查
自建錄音	高	清楚	成本高但品質可控

來源	取得難度	授權	注意事項
社群協作	中	需明確約定	品質參差

第三列在臺灣有豐富的資源，但也有最複雜的倫理考量：口述歷史的受訪者未必預期自己的聲音會被用於訓練 AI。第 8 章的知情同意原則在這裡必須被嚴格執行，而那可能意味著要重新取得同意。

第五列是低資源語言最有潛力的方向：社群協作的錄音與標註。它同時解決了資料量與代表性的問題——但需要清楚的授權約定與品質控制流程。

39.3 臺語的特殊挑戰

39.3.1 書寫系統的多樣性

臺語沒有單一的標準書寫方式，這對資料建置造成直接的困難。

系統	地位	範例	挑戰
臺羅	教育部推薦	tâi-gí	拼音、有聲調符號
漢字	傳統	台語	一字多音、用字不統一
漢羅混寫	實務常見	講 tsit-ê	兩種系統混用
白話字 (POJ)	教會傳統	tâi-gí	與臺羅相近但有差異

這個多樣性有兩個實務後果。第一，同一句話可能有四種寫法，而它們在模型眼中是不同的字串——這嚴重稀釋了本來就少的資料。第二，評測時的比對變得複雜：一個「正確」的答案可能因為用了不同的書寫系統而被判錯。

39.3.2 書寫系統的處置

策略	做法	優點	缺點
统一到臺羅	全部轉成拼音	一致、可計算	失去漢字的語意線索
统一到漢字	全部轉成漢字	較符合閱讀習慣	用字需標準化
雙軌並存	同時記錄兩種	彈性	資料量加倍

策略	做法	優點	缺點
以臺羅為內部表示	輸出時再轉換	兼顧	需要轉換器

第四列是本書建議的：內部用臺羅（無歧義、可計算），輸出時依使用者的偏好轉換。這與第 6.5 節處理民國紀年的策略相同——內部用一種標準表示，介面層做轉換。

39.3.3 變調與其他語言學挑戰

現象	說明	對系統的影響	章節
連續變調	字在詞中的調與單念時不同	語音與文字非一對一	本節
文白異讀	同字在不同詞中讀音不同	增加歧義	同上
方言差異	各地腔調不同	訓練與評測需涵蓋	39.4.2
借詞與混用	日語、華語、英語的借詞	詞彙邊界模糊	第 7 章
缺乏標準化	用字與用詞不統一	資料清理困難	39.3.1

第一列是臺語最顯著的語言學特徵之一：「台」單念是第五聲，在「台北」中變成第七聲。這意味著從語音到文字、或從文字到語音的對應都不是簡單的查表——而那影響了 ASR 與 TTS 兩個方向。

第四列在實務上很常見：日常的臺語對話中夾雜華語與日語借詞是常態。一個把它們當成錯誤來過濾的資料清理流程，會刪掉大量真實的語料——這與第 9 章清理繁中語料時的判斷類似。

39.3.4 評測的特殊考量

問題	為什麼特殊	處置	章節
多種書寫系統	同義但字串不同	正規化後比對	39.3.2
變調的標註	標本調還是變調	規範必須明訂	39.3.3
方言差異	哪種腔調算標準	分腔調報告	第 36.2.3 節
評測者稀少	懂臺語又懂技術的人少	與語言專家合作	第 34.5 節

最後一列是低資源語言研究的實際困難：評測需要語言能力，而那個能力在技術社群中不常見。第 34.5 節的做法在這裡同樣適用——與語言專家合作，並用配對比較降低他們的負擔。

39.4 語音應用的設計

39.4.1 適合的場景

場景	為什麼適合	風險	章節
固定用語的查詢	詞彙範圍小、錯誤率低	低	39.2.2
語音轉錄的初稿	人會校對	低	39.4.4
長照與陪伴	長者可能只說臺語	中（需謹慎）	39.4.5
文化保存與教學	記錄與傳承	低	本節
即時的關鍵決策	錯誤率太高	極高，不建議	39.4.4

第三列在臺灣有真實的需求：許多長者的主要語言是臺語或客語，而現有的數位服務多以華語為主。但它也需要最謹慎的設計——因為使用者可能無法察覺系統的錯誤。

39.4.2 資料收集的設計

面向	要涵蓋什麼	為什麼	章節
腔調	各主要腔調	避免只服務單一族群	39.3.3
年齡	含長者的語音	目標使用者常是長者	39.4.1
性別	平衡	聲學特徵不同	本節
錄音環境	含嘈雜的環境	真實使用不在錄音室	同上
領域	目標應用的用語	通用語料不足以支撐	第 22 章

第二列與第四列常被忽略但很關鍵：如果訓練資料全是年輕人在安靜環境中的清晰發音，那系統在真實的長照場域中會失效。而那正是最需要它的場景。

39.4.3 同意與倫理

議題	要處理什麼	做法	章節
知情同意	受訪者是否理解用途	白話的說明、可撤回	第 8.2 節
語音的識別性	聲音本身可識別個人	視為個資處理	同上
文化的所有權	族語屬於社群	與社群協商	本節
成果的回饋	社群能否受益	開放給社群使用	同上
再利用	資料能用於其他專案嗎	同意的範圍要明確	第 8.3 節

第三列與第四列在原住民族語的情境中特別重要：族語不只是資料，也是社群的文化資產。國際上有相關的原則討論（資料主權、社群同意），而在臺灣，與族群社群的協商應該是專案的一部分，而非事後的手續。

第四列有一個實務上的建議：把成果回饋給社群——例如把訓練出的模型或工具開放給該社群使用。這讓資料的提供不只是單向的取用。

39.4.4 錯誤傳遞的處置

39.1.3 節提過管線式架構的弱點。在臺語 0.15 的字元錯誤率下，這個問題必須被正面處理。

做法	說明	效果	章節
顯示轉錄供確認	讓使用者看到 ASR 的結果	最有效	本節
多候選	提供數個可能的轉錄	使用者可選	第 14 章
信心標示	低信心的詞標示出來	引導注意力	第 27.5 節
領域詞彙的偏置	限制在已知的詞彙	大幅降低錯誤	第 30.4.4 節
關鍵資訊的確認	重要的數字或名稱請使用者複述	避免嚴重錯誤	第 34.2.3 節

第一列是最簡單也最有效的：把 ASR 的結果顯示出來，讓使用者能看到系統聽到了什麼。這把一個無聲的錯誤變成一個可被發現的錯誤——而那正是第 34.2.3 節「降低錯誤代價」的原則。

第四列在固定場景中效果驚人：如果你的應用只涉及五十個藥品名稱，把辨識限制在那五十個之內，

錯誤率會大幅下降。這與第 29.4 節的文法約束是同一個思路。

39.4.5 長照場域的特殊考量

考量	為什麼	設計	章節
使用者可能無法察覺錯誤	認知或聽力的限制	關鍵資訊需人員確認	39.4.4
不該取代人際互動	陪伴的價值在於人	定位為輔助工具	本節
隱私極度敏感	涉及健康與私人生活	本地處理、嚴格存取	第 26、8 章
錯誤的代價高	可能影響照護決定	不做醫療判斷	第 34.2.3 節
家屬的期待	可能過度信任	明確揭露限制	第 37.6.4 節

第二列值得展開：一個能用臺語對話的系統，可能被期待成「陪伴」的替代品。而那在倫理上是有問題的——它可能減少真實的人際互動，而那正是長者最需要的。

本書的立場與第 32.5.1 節一致：系統的價值在於把人從重複的工作中解放出來，好讓他們去做真正需要人的事——而陪伴正是那類事。

39.4.6 一個語音應用的完整設計

把 39.4.1 到 39.4.5 節整合成一個實際的架構。

deploy/voice_spec.yaml

```

service: 農事語音查詢
language: 臺語（臺灣閩南語）
version: "1.0"

architecture:
  type: pipeline # 39.1.3 節
  asr:
    model: 自監督預訓練後微調
    training_hours: 8 # 自建錄音
    vocabulary_bias: true # 39.4.4 節
    domain_vocab: data/farm_terms.txt # 約 200 個詞
  llm: formosa-3b-tw-sft-dpo # 第 6 篇的模型
  output_language: 臺語或華語（使用者可選）

orthography:
  internal: tailo # 39.3.2 節
  display: 使用者偏好（漢字／臺羅／漢羅）
  converter: formosa/taigi/convert.py

```

```

error_mitigation:                # 39.4.4 節
  show_transcription: true        # 最重要的一項
  n_best: 3                       # 提供候選
  low_confidence_marking: true
  critical_confirm: [數量, 日期, 藥劑名]

measured:                        # 實測值
  cer_overall: 0.19
  cer_domain_terms: 0.07         # 詞彙偏置後
  cer_without_bias: 0.31         # 對照
  by_accent: {偏泉: 0.17, 偏漳: 0.21}
  by_environment: {安靜: 0.14, 田間: 0.26}
  measured_at: "2026-08-30"

ethics:
  consent_form: docs/consent_taigi.pdf # 含臺語口頭說明
  data_scope: 僅限本專案, 可撤回
  community_benefit: 模型與工具開放給農會使用

notes: |
  田間環境的錯誤率明顯較高 (0.26), 使用時建議
  在較安靜處操作。轉錄一律顯示供確認。
  已知限制: 僅涵蓋偏泉與偏漳兩種腔調。

```

三個設計要點。第一，詞彙偏置的效果被實測出來 (0.31 降到 0.07)，那讓「該不該做這件事」變成一個有依據的決定。第二，分腔調與環境報告，而 notes 誠實說明田間的表現較差。第三，ethics 區段記錄了同意的範圍與社群的回饋——那是低資源語言專案不可省的部分。

critical_confirm 那個欄位對應 39.4.4 節的最後一列：數量、日期、藥劑名這類關鍵資訊，系統應主動請使用者複述確認。在農事場景中，一個藥劑名稱聽錯可能造成實際的損害。

39.5 視覺語言動作模型

39.5.1 架構

把第 38 章的視覺語言模型再接上一段「動作」，就得到具身系統的基本形式。

元件	做什麼	輸出	章節
視覺編碼器	看到環境	影像的向量	第 38.1 節
語言模型	理解指令並規劃	文字或動作的描述	第 3 篇
動作解碼器	把規劃轉成控制指令	關節角度或位移	39.5.2

這個架構與第 38 章同構——只是把「生成文字」換成「生成動作」。而動作也可以被離散化成詞元，用同一套自迴歸的機制產生。

39.5.2 動作的表示

表示	說明	優點	缺點
離散化的動作詞元	把連續值分箱成詞元	可用語言模型直接生成	精度受分箱限制
連續的迴歸頭	直接輸出數值	精度高	需另一套解碼器
高階的技能標籤	「抓取」「移動到」	可組合、可解釋	需預先定義技能庫

第三列在實務上最務實，也最符合本書的立場：讓模型做高階的規劃，而低階的控制交給傳統的方法。理由在下一節。

39.5.3 延遲的硬限制

這是具身系統與前面所有應用最大的差異：物理世界有嚴格的時間要求。

階段	延遲	占比	說明
視覺感知	30 ms	3.1%	編碼器
語言理解與規劃	800 ms	81.6%	語言模型
動作生成	50 ms	5.1%	解碼器
執行與回饋	100 ms	10.2%	致動器
合計	980 ms	100%	—

把它與控制的頻率要求對照：

層次	頻率	每步的時間	LLM 來得及嗎
高階規劃	1 Hz	1,000 ms	可以
動作序列	10 Hz	100 ms	不行

層次	頻率	每步的時間	LLM 來得及嗎
關節控制	100 Hz	10 ms	完全不行
力回饋	1,000 Hz	1 ms	完全不行

這張表給出本節最重要的結論：語言模型的 800 毫秒只夠做高階規劃，不能進入控制迴路。任何需要 10 Hz 以上的控制，都必須由傳統的控制器處理。

正確的架構因此是分層的：語言模型決定「要做什麼」（每秒一次），傳統控制器決定「怎麼做」（每秒一百次）。這也是為什麼 39.5.2 節建議用高階的技能標籤——它們正是這兩層之間的介面。

39.5.4 具身系統的風險分級

第 32.3.1 節的分級在具身系統上有一個新的維度：物理的不可逆性。

動作	狀態改變	可逆性	風險
查詢感測資料	唯讀	可逆	低
規劃路徑（不執行）	僅輸出	可逆	低
移動到指定位置	物理移動	部分可逆	高
抓取或操作物件	物理接觸	可能不可逆	高
在人附近作動	人身安全	不可逆	極高

最後一列是絕對的界線：涉及人身安全的動作不該由語言模型的判斷決定。它可以參與規劃，但執行必須經過獨立的安全機制（例如物理的安全圍籬、力矩限制、緊急停止）——而那些機制不依賴 AI。這與第 32.3.2 節「極高風險不由 Agent 執行」是同一個原則，只是在物理世界中，違反它的後果更嚴重且完全不可逆。

39.5.5 安全機制的設計

層次	做什麼	是否依賴 AI	章節
物理限制	力矩上限、速度上限、圍籬	否	本節

層次	做什麼	是否依賴 AI	章節
獨立的安全控制 器	偵測異常即停止	否	同上
動作的預檢查	模擬後再執行	部分	同上
人的監督	可隨時介入	否	第 32.5 節
語言模型的規劃	決定要做什麼	是	39.5.3

這五層的排序是刻意的：最重要的三層都不依賴 AI。這與第 37.3.1 節的縱深防護是同一個邏輯——如果最關鍵的防線依賴一個可能出錯的元件，那整個系統就不安全。

第三列的「模擬後再執行」在機器人領域是成熟的做法：先在模擬環境中驗證這個動作不會碰撞或超出限制，再送到實體。它能擋掉大部分規劃層的錯誤。

39.6 臺灣的具身應用場景

39.6.1 四個場域

場域	需求	風險等級	章節
產線的檢測與分類	視覺判斷加簡單動作	中	第 34.3.1 節
倉儲的搬運	導航與取放	高	39.5.4
實驗室的自動化	重複的操作流程	中	本節
長照的輔助	取物、提醒	極高（在人附近）	39.4.5

前三列的共同特徵是在人與機器分離的環境中作業，那讓風險可控。第四列則不同——它必須在人的旁邊運作，而那是最高風險的情境（39.5.4 節）。

39.6.2 語言介面的價值

傳統做法	語言介面的改變	效益	限制
寫程式指定動作	用自然語言描述任務	非工程人員也能用	需要明確的表達
固定的流程	可依情況調整	彈性	不可預測性上升
預先定義所有情況	處理未見過的組合	涵蓋面廣	可靠度較低

第一列是具身應用中語言模型最實在的價值：讓現場的操作人員能直接指揮機器，而不必透過工程師。

這與第 34 章「把資深人員從重複工作中解放」是同一個方向。

但第二、三列的括號提醒了代價：彈性的另一面是不可預測。而在物理世界中，不可預測意味著風險——所以 39.5.5 節的安全層才那麼重要。

39.6.3 與臺語的結合

一個臺灣特有的組合：用臺語指揮的具身系統。

場景	為什麼有價值	挑戰	章節
傳統產業的現場	資深師傅慣用臺語	ASR 的錯誤率	39.2.2
長照的輔助	長者的主要語言	同上，且風險更高	39.4.5
農業與漁業	同樣的語言背景	環境噪音	39.4.2

這個組合的技術挑戰是複合的：臺語 ASR 的 0.15 錯誤率，加上具身動作的不可逆性。所以它必須用最保守的設計——確認轉錄、限制詞彙、以及獨立的安全機制。

但它的社會價值也是明確的：如果一個工具只能用華語操作，那些習慣講臺語的資深工作者就被排除在外。而那正是第 1 章那個問題在具身場域的版本。

39.7 語言保存的視角

39.7.1 技術與語言存續

本章的技術問題底下有一個更大的問題：數位工具支援哪些語言，會影響那些語言的使用。

機制	說明	方向	章節
使用的便利性	能用母語操作就會用	正面	39.6.3
內容的產生	工具讓內容更容易被記錄	正面	39.7.2
資料的累積	使用產生更多資料	正面循環	同上
資源的集中	主流語言得到更多投入	負面	39.2.1
標準化的壓力	技術偏好單一的書寫系統	需謹慎	39.3.2

第三列描述了一個正向循環：有工具 → 有人用 → 產生更多資料 → 工具更好。而低資源語言的困境正是這個循環還沒啟動——資料太少，做不出好用的工具；沒有好用的工具，就不會產生資料。

第五列則是一個需要警惕的風險：為了技術上的方便而推動單一的書寫標準，可能壓縮既有的多樣性。

39.3.2 節建議「內部用臺羅、輸出時轉換」，部分就是為了避免這件事。

39.7.2 技術能做什麼

貢獻	做什麼	需要什麼	章節
降低記錄的門檻	自動轉錄口述資料	ASR	39.1
輔助學習	發音回饋、對話練習	ASR 加 TTS	本節
內容的產生	協助創作與翻譯	生成能力	第 23 章
檢索與近用	讓既有的語料可被搜尋	第 30 章的方法	第 30 章
跨世代的傳遞	長輩的口述能被年輕人理解	轉錄與翻譯	39.1.3

第一列可能是最實在的貢獻：臺灣有大量的口述歷史錄音，但缺乏轉錄的人力。一個即使有 0.15 錯誤率的 ASR，也能把「完全無法搜尋」變成「可以搜尋、再人工校對」——而那是一個質變。

39.7.3 技術做不到的

限制	為什麼	意涵	章節
不能創造使用的動機	語言存續靠人使用	工具是輔助而非解方	本節

限制	為什麼	意涵	章節
不能取代語言社群	活的語言在人的口中	需與社群合作	39.4.3
不能解決資源的落差	資料的差距是結構性的	需要長期投入	39.2.1
不能決定書寫的標準	那是社群的決定	技術應適應而非主導	39.3.2

這四項是本節想強調的：技術能降低門檻，但不能代替使用。一個沒有人說的語言，即使有最好的 ASR 與 TTS，仍然會消失。

本書的立場因此是謙遜的：技術工作者能做的是把工具做好、把門檻降低、並把成果回饋給社群——而語言的存續最終取決於社群自己的選擇與努力。

程式實作

本章的實作依你的取向可以選擇語音或具身其中一條路線，或兩者都做。

程式 39A 語音的成本與能力量測

項目	要做什麼	驗收標準	節次
詞元成本	不同表示方式的實測	與 39.1.1 節相符	39.1.1
管線 vs 端到端	成本與品質的對照	含錯誤傳遞的分析	39.1.3
ASR 錯誤率	在你的領域上量測	含關鍵詞的正確率	39.2.2
詞彙偏置的效果	限制詞彙前後的對照	量化改善	39.4.4
腔調與環境	不同條件下的表現	分層報告	39.4.2
錯誤傳遞	ASR 錯誤對下游的影響	量化	39.4.4

關於第三項

不要只報告整體的字元錯誤率。關鍵詞（人名、地名、數字、專業術語）的正確率必須單獨統計——這與第 38.2.6 節的 `critical_accuracy` 是同一個原則。整體 0.15 但關鍵詞 0.40 的系統，在實際使用中不可用。

程式 39B 臺語資料的建置

目標：建立一小批可用的臺語語音資料，並處理書寫系統的問題。

必須完成的六項：

- 同意書與倫理說明：白話的、可撤回的（39.4.3 節）。
- 錄音規範：涵蓋腔調、年齡、環境（39.4.2 節）。
- 書寫系統的處置：內部表示與轉換器（39.3.2 節）。
- 標註規範：變調怎麼標、借詞怎麼處理。
- 一致性驗證：雙人標註與 κ （第 36.5.3 節）。
- 資料卡：來源、同意範圍、涵蓋的腔調與限制（第 8.6.2 節）。

第一項不是形式：如果你錄的是長輩的口述，他們未必理解「訓練 AI」是什麼意思。同意書必須用他們能理解的語言說明用途、範圍、以及如何撤回——而那可能需要用臺語口頭說明。

程式 39C 具身系統的安全設計

項目	要設計什麼	驗收	節次
分層架構	規劃層與控制層的分離	介面明確	39.5.3
延遲預算	各層的實測	對照 39.5.3 節	同上
風險分級	所有動作的分級	極高風險被排除	39.5.4
安全層	五層，其中三層不依賴 AI	各自可測試	39.5.5
模擬預檢	執行前的碰撞檢查	能擋下不當的規劃	同上
緊急停止	獨立於軟體的機制	實際測試過	同上

延伸挑戰：刻意讓語言模型產生一個危險的規劃（例如撞向障礙物），看安全層是否擋下。這是第 37 章紅隊測試在具身系統上的版本——而它的結果必須是「擋下」，因為那裡沒有容錯的空間。

系統案例：臺語語音查詢或具身輔助

本章的系統案例提供兩個選項，依你的資源與取向擇一。

選項 A：臺語的語音查詢

要素	要求	章節
場景	固定用語的查詢（如農事、產線、長照）	39.4.1
資料	至少 5 小時自建錄音，含同意書	39.4.3
架構	管線式，含轉錄的顯示	39.4.4
詞彙偏置	限制在領域詞彙內	同上
評測	整體與關鍵詞分開報告	39.2.2
倫理	同意、隱私、成果回饋	39.4.3

選項 B：具身系統的安全設計

要素	要求	章節
場景	產線或實驗室（人機分離）	39.6.1
架構	規劃層與控制層分離	39.5.3
延遲	各層的實測與預算	同上
風險分級	所有動作，含排除的項目	39.5.4
安全層	五層，含三層不依賴 AI	39.5.5
紅隊	刻意產生危險規劃的測試	程式 39C

兩個選項共同的交付

1. 成本量測：語音的詞元成本或具身的延遲預算。
2. 能力的實測：在你的實際條件下能做到什麼。
3. 失效分析：最常見的錯誤與它們的後果。
4. 風險分級與排除的項目：哪些不做、為什麼。
5. 倫理與同意：資料的來源與使用範圍。
6. 一頁反思：這個技術對臺灣的實際價值與限制。

評分重點

- 關鍵詞或關鍵動作是否單獨評測，而非只有整體指標。
- 是否明確排除了高風險的應用並說明理由。
- 語音路線：轉錄是否顯示給使用者確認。
- 具身路線：最關鍵的安全層是否不依賴 AI。
- 資料的同意是否用受訪者能理解的方式取得。
- 第六項的反思是否誠實面對技術的限制。

最後一項延續本章 39.7.3 節的立場。做完之後你很可能會發現：技術的部分不是最難的，最難的是資料、同意、以及「這真的有幫助嗎」這個問題。而能誠實面對那個問題，比做出一個炫目的展示更接近工程的本質。

章末評量

一、概念題

1. 語音的四種表示方式各有什麼取捨？
2. 為什麼語音的成本是文字的五到十倍？這對架構有什麼意涵？
3. 管線式與端到端架構的取捨是什麼？本書為什麼建議前者為起點？
4. 臺語有哪四種書寫系統？這對資料建置造成什麼困難？
5. 什麼是連續變調？它對 ASR 與 TTS 有什麼影響？
6. 為什麼自監督預訓練對低資源語言特別重要？
7. 為什麼說「語言模型不能進入控制迴路」？
8. 具身系統的安全層中，為什麼最重要的三層不該依賴 AI？
9. 技術對語言存續能做什麼、不能做什麼？

二、計算題

1. 語音編碼器每 20 毫秒一個向量。計算一分鐘語音的詞元數。
2. 中文語速 225 字/分、fertility 1.4。計算轉錄後的詞元數，並與上題比較。
3. 臺語約 500 小時、英語約 100 萬小時。計算比例。
4. 500 小時的語音，以每分鐘 225 字計，約相當於多少字的轉錄？
5. 具身系統的四階段延遲為 30、800、50、100 毫秒。計算總延遲與語言模型的占比。
6. 關節控制需要 100 Hz。計算每步可用的時間，並判斷 800 毫秒的規劃是否來得及。

三、除錯題

1. ASR 的整體字元錯誤率是 0.12，但使用者說「常常搞錯」。請說明該檢查什麼。
2. 系統在錄音室的測試中表現良好，但在長照機構中很差。請列出三個可能原因。
3. 同一句臺語，模型有時輸出漢字有時輸出臺羅。請說明問題與處置。
4. 具身系統的動作偶爾會超出安全範圍。請說明架構上可能的缺失。
5. 訓練資料全是年輕人的錄音，而目標使用者是長者。請說明後果。
6. 口述歷史的錄音被用於訓練，但受訪者當初只同意「學術研究使用」。請說明問題。

四、系統設計題

1. 你要為一個「客語的農事查詢」設計方案。客語的資料比臺語更少（約 100 小時），使用者多為長者、環境有噪音。請設計架構與降低錯誤代價的方案。

2. 你的實驗室要做一個「用語音指揮的實驗室助手」。請設計安全架構，並明確界定哪些動作絕對不由語音指令觸發。

五、臺灣情境與倫理題

1. 族語屬於語言社群的文化資產。請討論：在收集與使用族語資料時，該與社群建立什麼樣的關係？「成果回饋」應該包含什麼？
2. 一個能用臺語陪伴長者對話的系統，可能減少真實的人際互動。請討論：這樣的系統該不該做？如果做，該如何設計才能避免取代人？

評量提示（給自學者）

- 計算題第 1 題： $60 \text{ 秒} \div 0.02 \text{ 秒} = 3,000$ 個詞元。
- 計算題第 2 題： $225 \times 1.4 = 315$ 詞元；語音為其約 9.5 倍。
- 計算題第 3 題： $500 / 1,000,000 = 0.05\%$ 。
- 計算題第 4 題： $500 \times 60 \times 225 = 675$ 萬字。
- 計算題第 5 題：總延遲 980 毫秒；語言模型占 $800/980 \approx 81.6\%$ 。
- 計算題第 6 題：每步 10 毫秒；800 毫秒是它的 80 倍，完全來不及。
- 除錯題第 1 題：應檢查關鍵詞（人名、地名、數字、術語）的正確率。整體 0.12 但關鍵詞錯誤率可能高得多——見 39.4.4 節與第 38.2.6 節。

研究延伸與版本注意事項

- 語音的自監督表示學習：對低資源語言最重要的技術路線。
- 多語與跨語言的語音模型：從高資源語言遷移的方法。
- 臺語與客語的語音資源：國內有多個計畫在建置，狀態持續變動。
- 低資源語言的 ASR：資料增強、合成語音、以及主動學習的方法。
- 視覺語言動作模型：機器人領域近年最活躍的方向之一。
- 語言資料的倫理與社群同意：國際上有相關的原則討論，值得參考並在地化。
- 本章的資源量級數字變動快速（各計畫持續在建置語料），且技術進展明顯。所有能力的判斷都必須在當下的條件下重測。

常見問題

問：五百小時真的做不出好用的臺語 ASR 嗎？答：能做出「可用但需校對」的系統（39.2.2 節），而

那在很多場景中已經有價值——特別是轉錄口述資料（39.7.2 節）。關鍵是設計時就假設會錯，並讓錯誤能被發現（39.4.4 節）。

問：我該做語音還是具身？答：看你的資源與場域。語音的門檻較低（不需要硬體），而具身需要實體的設備與安全的環境。系統案例提供兩個選項，擇一即可。

問：可以用合成的臺語語音訓練嗎？答：可以作為補充，但不能取代真實的語音。理由與第 38.4.4 節相同：合成資料的分布與真實不同，而評測必須用真實資料。特別是腔調與環境噪音，合成很難模擬。

問：語言模型真的完全不能進控制迴路嗎？答：以目前的延遲而言是。但架構上可以讓它在較慢的層次持續運作——例如每秒重新規劃一次，而控制器以一百赫茲執行那個規劃。分層而非排除才是正確的理解。

教師使用建議

本章排在第 39 週，建議 2 小時講授加 1 小時討論。本章有較多的倫理與社會議題，適合安排討論而非只有實作。

時段	內容	互動設計	注意事項
前 20 分鐘	39.1 至 39.2 節，成本與資源落差	算萬分之五的比例	這個數字很有衝擊力
中間 25 分鐘	39.3 至 39.4 節，臺語的挑戰	看四種書寫系統的同一句話	多樣性的具體感受
後 25 分鐘	39.5 節，具身與延遲	算 800ms 對上 10ms	控制迴路的界線
最後 30 分鐘	39.7 節，語言保存	討論技術能與不能做什麼	這段值得充分討論
實作 1 小時	程式 39A 或 39C	依取向擇一	關鍵詞的評測必做

一個效果很好的開場：把同一句臺語用四種書寫系統寫在白板上，問學生「這是幾句話」。多數人會說四句，而答案是一句——那個瞬間的困惑，正是低資源語言在資料上面對的困難。

關於 39.7 節的討論：這是全書最接近人文關懷的一節。建議讓學生討論「技術工作者對語言存續有什麼責任」——這個問題沒有標準答案，但它讓學生思考自己的工作在更大的脈絡中的位置。而那正是一本教科書最後幾章該做的事。

高中授課的調整：39.1 用「聲音很佔空間」的直覺講成本；39.2 完整教（資源落差的比例是很好的

數學與社會議題結合)；39.3 做那個「四種寫法是幾句話」的活動——效果極佳；39.5 講延遲的限制（800ms 對 10ms 很直觀）；39.7 完整討論，這是很好的科技與社會教材。

附：低資源語言與具身速查表

把本章的關鍵數字與判準整理成一張表。

要算什麼	公式或判準	典型結果	節次
語音詞元數	秒數 ÷ 幀長	一分鐘、20ms 為 3,000	39.1.1
語音與文字的比值	語音詞元 ÷ (字數 × fertility)	約 9.5 倍	39.1.2
資源比例	本語言小時數 ÷ 英語	臺語約 0.05%	39.2.1
可達的錯誤率	依資料量的經驗值	500 小時約 0.15	39.2.2
詞彙偏置的效益	限制前後的 CER 對照	可降低一半以上	39.4.4
具身總延遲	感知 + 規劃 + 生成 + 執行	約 980 ms	39.5.3
LLM 的占比	規劃 ÷ 總延遲	約 82%	同上
控制頻率的界線	1/頻率 vs LLM 延遲	100 Hz 需 10ms，差 80 倍	同上
安全層的依賴	不依賴 AI 的層數	五層中應有三層	39.5.5

使用這張表的三個提醒。第一，語音與視覺一樣，非文字的模態都貴五到十倍——架構的第一選擇是先轉成文字。第二，低資源語言的錯誤率必須被納入設計，而非事後才處理。第三，具身系統的延遲限制是物理的，不會因為模型變好而消失——分層是唯一的解法。

本章小結

1. 語音的四種表示中，語音編碼器（每 20 毫秒一個向量）是目前最常見的。
2. 一分鐘語音約 3,000 個詞元，是文字轉錄的約 9.5 倍。
3. 因此架構的建議與第 38 章相同：能先轉成文字的就先轉。
4. 管線式架構便宜且可沿用第 7、8 篇的所有方法，但 ASR 的錯誤會傳遞。
5. 臺語的公開標註語音約 500 小時，是英語的萬分之五；原住民族語再少兩個數量級。

6. 500 小時能達到約 0.15 的字元錯誤率——可用但需人工校對。
7. 自監督預訓練是低資源語言最重要的槓桿，因為未標註的語音容易取得得多。
8. 臺語有四種書寫系統，這嚴重稀釋了本來就少的資料。
9. 建議內部用臺羅（無歧義、可計算），輸出時再依偏好轉換。
10. 連續變調讓語音與文字的對應不是一對一，影響 ASR 與 TTS 兩個方向。
11. 錯誤傳遞的最佳處置是顯示轉錄供使用者確認——把無聲的錯誤變成可被發現的。
12. 詞彙偏置在固定場景中效果驚人：限制在已知詞彙內能大幅降低錯誤。
13. 長照場域的系統不該取代人際互動——陪伴的價值正在於人。
14. 具身系統的語言模型延遲約 800 毫秒，只夠做每秒一次的高階規劃。
15. 關節控制需要 10 毫秒一步，語言模型完全來不及——必須分層。
16. 具身的風險分級多了物理的不可逆性；在人附近作動是絕對的界線。
17. 安全層的五層中，最重要的三層都不依賴 AI。
18. 技術能降低記錄與使用的門檻，但不能創造使用的動機。
19. 族語屬於社群的文化資產，成果應回饋給社群。

成果檢核

完成本章後你必須繳交（依選擇的路線）：

- 成本量測：語音的詞元成本或具身的延遲預算。
- 能力實測：在你的實際條件下能做到什麼，含關鍵詞或關鍵動作的單獨評測。
- 失效分析：最常見的錯誤與後果。
- 語音路線：資料建置（含同意書）、書寫系統的處置、錯誤傳遞的緩解。
- 具身路線：分層架構、風險分級、五層安全機制、危險規劃的紅隊測試。
- 排除的項目：哪些不做與理由。
- 一頁反思：這個技術對臺灣的實際價值與限制。

第 10 篇還剩最後一章。從第 1 章那個超額比序的錯誤答案開始，你走過了語料、tokenizer、Transformer、訓練、適配、對齊、檢索、Agent、部署、評測、安全——以及本章的語音與具身。

第 40 章不會教新的技術。它要做的是把這四十章整合成一件事：一個你自己選題、自己完成、並且能誠實說明它做得到什麼與做不到什麼的專題。

第 40 章

總整專題

Capstone Project

難度：整合 | 建議授課：第 40 週（全書末） | 硬體需求：依專題類型而定；知識系統路線不需 GPU

叫獸開講

第 1 章開場的那個問題——一個模型自信地講錯了臺灣的升學制度——現在你知道它為什麼會發生、以及要修好它需要什麼：語料、tokenizer、適配、檢索、引用驗證、拒答設計、評測、紅隊。這一章不教新技術，它要求你把那些東西整合成一件自己的作品，並誠實說明它做得到什麼、做不到什麼。

學習目標

完成本章的總整專題後，你應該能夠：

1. 選擇一個範圍適當、資源可負擔、且有實際價值的題目。
2. 整合前四十章的方法，建立一個端到端可運作的系統。
3. 建立能支撐決策的評測，並誠實報告不確定性。
4. 完成安全測試與治理文件。
5. 撰寫可交接的技術文件，讓他人能接手。
6. 向非技術背景的聽眾說明你做了什麼與為什麼。
7. 誠實評估這個系統的限制與未完成的部分。
8. 判斷它是否適合交給真實使用者。
9. 規劃後續的發展或退場。

這一章的性質

本章沒有新的技術內容——前三十九章已經足夠。它提供的是選題的框架、整合的清單、評分的規準、以及一份誠實的收尾。如果你在讀這一章時發現某個要求不知道怎麼做，那多半是某一章沒有讀完——本章的每一項要求都會標注對應的章節。

40.1 選題

40.1.1 三種規模

規模	總工時	團隊	適合什麼
小型	約 60 小時	個人	單一功能、範圍明確
中型	約 135 小時	2 至 3 人	完整系統、含評測與治理
大型	約 300 小時	實驗室團隊	含真實場域的試點

本章以中型為預設（一學期、三人、每人每週約 2.5 小時）。小型與大型的要求可依比例調整，但核心的紀律不變：評測要有依據、限制要誠實、文件要能交接。

40.1.2 選題的五個判準

判準	要問什麼	不合格的徵兆	章節
範圍可完成	這個學期做得完嗎	「我們要做一個通用的……」	第 34.6.2 節
資料可取得	知識從哪來、要多久	「應該可以找到吧」	第 34.4 節
能被評測	怎麼知道它做得好不好	「看起來還不錯」	第 36 章
有實際價值	誰會用、解決什麼問題	「很酷」	第 34.6.3 節
風險可承受	出錯會怎樣	涉及醫療或財務的判斷	第 34.2 節

第一列是最常見的失敗原因：範圍過大。一個「臺灣法規問答系統」做不完，但「本校學則的休學與復學查詢」可以——而後者的完成度會遠高於前者。

第三列則是本書一貫的要求：如果你想不出怎麼評測它，那就還不能開始做。這個判準能在選題階段就擋掉大量會失敗的專題。

40.1.3 題目的類型

類型	主軸	適合的背景	主要章節
知識系統	把某個領域的知識做成可查詢的系統	有領域接觸	第 28、30、31 章
本土化模型	把開放模型適配到特定的臺灣場域	有硬體資源	第 22 至 26 章

類型	主軸	適合的背景	主要章節
評測與分析	建立某個領域的臺灣評測集並分析	重視方法	第 36 章
邊緣部署	把模型放進受限的裝置	有硬體與應用場景	第 26、35 章
多模態應用	文件、語音或具身	有特定的資料	第 38、39 章
工具與框架	做一個讓別人好做的工具	工程取向	各章的程式實作

第三列常被低估：建立一個好的評測集，是一個完整且有價值的專題。第 36 章說過臺灣的評測資源稀缺，而一個經過嚴謹方法建立的評測集，對社群的貢獻可能大於又一個問答系統。

第六列同樣有價值：本書的每一章都有程式實作，而把它們整理成一個好用的工具是實在的貢獻。第 34.1.3 節說過「框架與內容分離」的重要性——一個能讓別人快速換場域的框架，正是這個原則的體現。

40.1.4 可行性的自我檢查

在確定題目之前，用第 34 章章末那十個問題檢查一次。

項次	問題	若答不出來	章節
1	可接受的錯誤率是多少	先算 (第 34.2.2 節)	第 34.2 節
2	目前的品質離門檻多遠	先量	第 36 章
3	能否用設計降低錯誤代價	先想	第 34.2.3 節
4	有無特殊的法遵要求	先問	第 37.7 節
5	知識在文件裡還是人腦裡	先確認	第 34.4.1 節
6	對方願意投入多少時間	先談	第 34.4.2 節
7	誰能做專業評測	先找	第 34.5.1 節
8	第一版會執行動作嗎	建議否	第 34.6.2 節
9	結案後誰維護	先規劃	第 33.7 節
10	若失敗還留下什麼	先想	第 34.7.2 節

第 34 章說過：如果第 6、7、9 題答不出來，就先不要開始。在專題的情境中，第 6 題可能是「指導老師願意投入多少時間」，第 9 題可能是「學弟妹會不會接手」——而它們同樣決定成敗。

40.2 整合前面的產出

40.2.1 可沿用的清單

如果你完成了前面各章的程式實作，那麼專題的多數元件已經存在。

篇	章	可沿用的產出	項數
第 1 篇	1–4	需求規格書、環境指紋與可重現的設定	2
第 2 篇	5–9	評測基準規格、自訓 tokenizer、語料清冊	3
第 3 篇	10–13	Transformer 實作與訓練腳本	1
第 4 篇	14–17	解碼工具箱、訓練迴圈、實驗紀律	3
第 5 篇	18–21	效能剖析器、算力預算書	2
第 6 篇	22–26	適配模型、指令資料集、LoRA、對齊、量化	5
第 7 篇	27–30	推理工具、知識庫、提示規格、RAG	4
第 8 篇	31–34	多跳檢索、Agent 框架、上線流程、提案	4
第 9 篇	35–37	服務部署、評測體系、紅隊與治理	3
第 10 篇	38–40	視覺或語音的模組	2

合計約 29 項。這意味著專題的工作不是從零開始，而是選擇、組合、與補上缺的部分——而那正是 40.1.1 節那 135 小時能完成一個完整系統的原因。

40.2.2 典型的組合

專題類型	核心組合	需要補的	章節
知識問答系統	第 28 + 30 + 31 + 33 章	領域知識與評測集	第 34.4 節
本土化模型	第 22 + 23 + 24 + 25 章	繁中語料與指令資料	第 9、23 章

專題類型	核心組合	需要補的	章節
評測集專題	第 36 章為主	題目與專家標註	第 34.5 節
邊緣部署	第 26 + 35 章	目標裝置與實測	第 26.6 節
文件處理	第 30 + 38 章	文件與 OCR 的品質量測	第 38.2.6 節

第一列是最常見也最務實的組合：知識問答系統可以完全不訓練模型，用現成的開放權重模型加上你自己建的知識庫與評測。這讓沒有 GPU 的團隊也能做出完整的專題。

40.2.3 不必全部做的部分

項次	什麼情況可以省	不可省的替代	章節
從零訓練模型	幾乎總是可省	用開放權重模型	第 22.1 節
自建 tokenizer	不做預訓練時	用底模的	第 7 章
分散式訓練	單卡夠用時	—	第 19 章
Agent 與工具	不需執行動作時	純問答即可	第 32.8.1 節
量化部署	不上邊緣時	—	第 26 章

第一列值得強調：第 17 章與第 22 章的計算已經證明，從零訓練對多數團隊不可行。專題應該用開放權重模型——那不是偷懶，而是本書一貫建議的正確路線。

第四列則呼應第 32.8.1 節：一個只讀不寫的系統，在多數場域中已經有價值，而它的風險低得多。除非你的專題主題就是 Agent，否則不必為了「看起來完整」而加上執行動作的功能。

40.2.4 一個典型專題的組裝

以最常見的「知識問答系統」為例，看它如何由前面各章的產出組裝而成。

專題的元件對照

專題：本校教務規章查詢助理

- └ 知識層
 - └ 知識庫（第 28.5 節的格式） ← 需自建
 - └ 含 valid_from / applies_to / 負責人
 - └ 切塊（第 30.3 節） ← 沿用程式 30A
 - └ 過時偵測（第 28.7 節） ← 沿用

└ 檢索層	
└ 混合檢索（第 30.2 節）	← 沿用程式 30B
└ 多跳與路由（第 31.2、31.4 節）	← 沿用程式 31A
└ 快取（第 31.6 節）	← 沿用程式 31C
└ 生成層	
└ 模型：開放權重（不自行訓練）	← 40.2.3
└ 提示與 schema（第 29 章）	← 沿用程式 29A，需改內容
└ 引用驗證（第 30.5 節）	← 沿用
└ 服務層	
└ 批次與快取（第 35 章）	← 沿用（若自建部署）
└ 降級與監控（第 33.4、33.5 節）	← 沿用程式 33B
└ 介面（第 33.3 節）	← 需實作
└ 品質與治理	
└ 評測集（第 36.4 節）	← 需自建
└ 統計工具（第 36.1 節）	← 沿用程式 36A
└ 紅隊（第 37.1 節）	← 沿用程式 37A，需改攻擊
└ 影響評估（第 37.6.3 節）	← 需撰寫

標示為「需自建」的只有四項：知識庫、評測集、介面、影響評估。其餘的都能沿用——而那正是 40.3.1 節那個「系統實作只占 19%」的原因。

這張圖也說明了 40.1.2 節第二個判準的重要性：四項需自建的項目中，有兩項（知識庫與評測集）都是資料工作。如果你的領域知識取得不了，那專題的一半就無法完成。

40.3 工時的配置

40.3.1 八個階段

階段	工時	占比	說明
選題與範圍界定	8	6%	含可行性的十問
資料與知識建置	30	22%	最大的一塊
系統實作	25	19%	沿用既有的框架
評測集建立	18	13%	含人工標註
評測與改善	20	15%	迭代
安全與治理	12	9%	紅隊與影響評估
文件與交接	12	9%	含交接的驗收
報告與展示	10	7%	—

(合計 135 小時。一學期 18 週，每週約 7.5 小時；三人團隊每人每週約 2.5 小時。)

兩個觀察。第一，資料與評測加起來占 35%——與第 34.1.2 節的分析一致。第二，系統實作只占 19%，因為框架是沿用的。

這個配置對規劃有直接的意涵：如果你的專題把八成的時間花在寫程式上，那配置就錯了。而那通常導致一個能跑但無法評估、無法交接的成果。

40.3.2 時程的建議

週次	做什麼	產出	章節
1–2	選題、可行性、範圍界定	一頁的專題定義	40.1
3–6	資料與知識建置	知識庫或語料	第 9、28、34 章
5–9	系統實作（可與資料並行）	可運作的原型	第 30、31 章
8–11	評測集建立	至少 100 題	第 36 章
10–14	評測與改善	評測報告與迭代紀錄	第 16、36 章
13–15	安全與治理	紅隊報告、影響評估	第 37 章
15–17	文件與交接	交接文件、他人試讀	第 33.7 節
16–18	報告與展示	書面報告與口頭簡報	40.5

注意有幾個階段是重疊的：資料建置與系統實作可以並行（先用少量資料把系統跑通），而評測集的建立最好在系統完成前就開始——那樣你才能在改善時有依據。

40.3.3 常見的時程失誤

失誤	後果	預防	章節
資料建置低估	後面全部壓縮	第 3 週結束前應完成一半	第 34.6.1 節
評測留到最後	沒時間改善	第 8 週就要開始	第 36 章
文件留到最後	交不出可用的文件	邊做邊寫	第 33.7.3 節
一直在調整範圍	什麼都沒完成	第 2 週結束就凍結	40.1.2

失誤	後果	預防	章節
忽略安全與治理	無法上線	排進時程	第 37 章

第二列是最致命的：如果評測到第 15 週才建好，那你只剩三週可以改善，而且改了也不知道有沒有用。第 16 章的實驗紀律要求先有評測再做改動——在專題中同樣適用。

40.4 交付清單

40.4.1 必須交付的九項

項次	交付物	要求	章節
1	專題定義	範圍、不做什麼、成功的判準	第 33.1.3 節
2	可運作的系統	他人能依文件跑起來	第 33.7.3 節
3	資料或知識庫	含來源、授權、清冊	第 8 章
4	評測集	至少 100 題，含分層與來源標記	第 36.4 節
5	評測報告	含區間、分層、caveats、失敗案例	第 36.2.3 節
6	安全測試	紅隊報告，含未擋住的案例	第 37.1.5 節
7	治理文件	風險矩陣、殘餘風險、揭露文字	第 37.6 節
8	交接文件	經過他人試讀驗證	第 33.7.3 節
9	限制說明	做不到什麼、為什麼	本節

第九項是本書最重視的一項，也是全書精神的總結：能清楚說出自己做不到什麼，比展示做得到什麼更專業。

40.4.2 依專題類型的調整

類型	加重	可減輕	章節
知識系統	知識庫、引用驗證	模型訓練	第 28、30 章
本土化模型	訓練紀錄、回歸測試	應用層	第 22、23 章
評測集專題	方法的嚴謹、一致性	系統實作	第 36 章
邊緣部署	實測、四維度評測	知識庫	第 26.8 節
多模態	能力探測、幻覺測試	同上	第 38.7 節

但無論哪一類，第 40.4.1 節的第 1、5、8、9 項都不可減輕：專題定義、評測報告、交接文件、限制說明。它們是「這個成果能不能被別人理解與使用」的最低條件。

40.4.3 評測報告的最低要求

第 36.2.3 節給過完整的格式，這裡是專題的最低版本。

- 題數與分層的分布（第 36.4.5 節）。
- 整體與各層的正确率，皆附 95% 信賴區間（第 36.2.1 節）。
- 「這個題數能偵測多大的差異」的計算（第 36.1.1 節）。
- 污染檢查：題目來源與金絲雀的結果（第 36.3 節）。
- 若有版本比較：配對檢定與誠實的結論（第 36.1.4 節）。
- 至少 10 個失敗案例與分析（第 16.6.3 節）。
- caveats：評測者的偏誤、未涵蓋的部分（第 36.5.4 節）。

第三項是最容易被略過但最能反映統計素養的：先算出你的評測能區分多大的差異，再決定要不要宣稱某個改善。

40.4.4 常見的交付缺失

從前面各章的系統案例累積下來，最常見的缺失有六類。

缺失	樣子	為什麼是問題	章節
只有點估計	「正確率 89.3%」	無法判斷可信度	第 36.2.4 節
只展示成功	示範全是漂亮的案例	看不出真實水準	第 16.6.3 節

缺失	樣子	為什麼是問題	章節
限制寫得籠統	「未來會改善效能」	沒有資訊量	40.5.1
文件只有自己看得懂	缺少環境與步驟	無法交接	第 33.7.3 節
評測用了調校過的資料	沒有保留集	高估	第 5.4 節
沒有處理多版本	同一問題對不同人答案不同	對一半的人是錯的	第 28.5.3 節

第六列在臺灣的校務類專題中特別常見：學則因入學學年度而異，而一個不處理這件事的系統，對一部分學生給的是錯誤答案。第 28.5.2 節的 `answer_requires` 與第 30.6.2 節的版本過濾就是為此。

第五列則是一個容易無意間犯的錯：在調整提示或參數時看了測試集，那個測試集就不再是保留集。第 5.4 節的三分切分（訓練、驗證、保留）在專題中同樣必要。

40.5 報告與展示

40.5.1 書面報告的結構

章節	內容	長度	章節
一、問題	要解決什麼、現況如何	1 頁	第 34.7.2 節
二、範圍	做什麼、明確不做什麼	1 頁	第 33.1.3 節
三、方法	架構與關鍵的設計決定	3 至 5 頁	各章
四、評測	方法、結果、不確定性	3 至 4 頁	第 36 章
五、安全	紅隊、風險、殘餘風險	2 頁	第 37 章
六、限制	做不到什麼、為什麼	1 至 2 頁	本節
七、結論與後續	學到什麼、下一步或退場	1 頁	第 34.7.2 節

第三章的「關鍵的設計決定」比「用了什麼技術」重要。讀者想知道的是你為什麼那樣選，以及考慮過哪些替代方案——那才是工程判斷的展現。

第六章不該只有一句「未來會改善」。具體地說出哪些情況會失敗、失敗率大約多少、以及為什麼沒有解決——那需要誠實，也需要對自己的系統有深入的理解。

40.5.2 口頭展示的設計

時段	講什麼	時間	注意
問題	用一個具體的例子開場	2 分鐘	不要從技術講起
示範	實際跑一次	3 分鐘	含一個失敗的案例
方法	架構與關鍵決定	4 分鐘	不要逐章複述
評測	數字與不確定性	3 分鐘	含區間
限制	做不到什麼	2 分鐘	這段最有價值
問答	—	6 分鐘	—

第二列的「含一個失敗的案例」是本書建議的做法，理由與第 16.6.3 節相同：只展示成功案例的示範，聽眾無法判斷系統的真實水準。而主動展示失敗，反而讓其他的宣稱更可信。

第五列同樣重要：一個花兩分鐘誠實說明限制的展示，比一個完美無瑕的展示更專業。有經驗的聽眾知道任何系統都有限制，而不提它們只會讓人懷疑其餘的部分。

40.5.3 給非技術聽眾的說明

要說明的	該怎麼說	不該怎麼說	章節
它做什麼	用具體的使用場景	講模型架構	第 33.3 節
它多可靠	「大約每十次有一次需要查證」	「準確率 89.3%」	第 36.2.4 節
它會怎麼錯	舉一個實際的例子	「可能有幻覺」	第 33.3.5 節
該怎麼用	什麼時候要人工確認	「請自行判斷」	第 37.6.4 節
資料怎麼處理	存哪裡、誰能看、留多久	「符合規範」	第 8 章

第二列的差異值得說明：「準確率 89.3%」對非技術聽眾沒有意義，而「大約每十次有一次需要查證」

直接告訴他們該怎麼使用。這與第 33.3.3 節「明說缺什麼比信心分數有用」是同一個原則。

40.6 評分規準

40.6.1 六個面向

面向	看什麼	權重	章節
完成度	系統可運作、範圍內的功能齊備	20%	40.4.1
方法的嚴謹	設計有依據、決定可被檢驗	20%	各章
評測的品質	有依據、有區間、有失敗案例	25%	第 36 章
誠實與限制	清楚說出做不到什麼	15%	40.4.1
可交接性	他人能接手	10%	第 33.7.3 節
臺灣情境的掌握	在地的需求與限制被處理	10%	各章

評測的品質權重最高（25%），這是刻意的。一個功能較少但評測嚴謹的專題，勝過一個功能很多但說不清楚好壞的專題——因為前者知道自己在哪裡，而後者不知道。

第四項的 15% 也值得說明：誠實不是扣分項的反面，而是一個獨立的加分項。清楚指出限制、誠實報告失敗、不宣稱超過證據的東西——這些都是專業能力的展現。

40.6.2 各面向的評分細則

等級	完成度	評測品質	誠實與限制
優	功能齊備且穩定	有區間、分層、污染檢查	具體列出失敗情境與比例
良	主要功能可運作	有區間但分層不足	有提到限制但較籠統
可	能示範但不穩定	只有點估計	只寫「未來會改善」
待改進	無法完整運行	無法判斷好壞	未提限制

「可」與「良」在評測品質上的差異，正是第 36.2.4 節那個「過度精確」的問題：只報告 0.893 而沒

有區間，讀者無法判斷那個數字有多可信。

40.6.3 不予計分的情況

- 評測結果無法重現（缺少設定、種子、環境指紋）——第 4.7 節。
- 引用了不存在的來源（杜撰出處）——第 30.5.3 節。
- 報告只有成功案例，沒有失敗案例——第 16.6.3 節。
- 使用了未經授權的資料——第 8.3 節。
- 涉及個資但未經去識別或同意——第 8.2 節。
- 宣稱的改善在統計上無法支持，且未說明——第 36.1 節。

這六項都不是「做得不夠好」，而是違反了基本的研究與工程誠信。它們在學術與業界都是嚴重的問題，而在一個教學的情境中明確標示出來，是本書認為必要的。

40.6.4 自我檢查表

在繳交之前，用這份表逐項確認。它整合了全書的核心紀律。

項次	檢查什麼	通過標準	章節
1	範圍已明確定義，含「不做什麼」	一句話說得清楚	第 33.1.3 節
2	資料的來源與授權已記錄	含清冊與確認人	第 8.3 節
3	涉及個資者已去識別或取得同意	有紀錄	第 8.2 節
4	環境可重現	指紋、種子、設定齊備	第 4.7 節
5	評測集未被用於調校	保留集分離	第 5.4 節
6	評測結果附信賴區間	不只有點估計	第 36.2.1 節
7	已算過可偵測的最小差異	據此判斷結論	第 36.1.1 節
8	污染檢查已執行	含題目來源的標記	第 36.3 節
9	引用的來源皆存在	零杜撰	第 30.5.3 節
10	含「不該答」的測試	15% 至 20%	第 36.4.5 節
11	失敗案例至少 10 個	含分析	第 16.6.3 節
12	紅隊測試已執行	含未擋住的案例	第 37.1.5 節

項次	檢查什麼	通過標準	章節
13	殘餘風險已計算並標示不為零	有具名的接受	第 37.4 節
14	交接文件經他人試讀	一小時內可跑起來	第 33.7.3 節
15	限制說明具體	非「未來會改善」	40.5.1
16	給後來者的筆記已寫	含「什麼無效」	40.7.3

這十六項中，第 9、11、12、13 項對應 40.6.3 節的不予計分條件——它們不是加分項，而是及格的門檻。

而第 15 與 16 項是本書認為最能區分成熟度的兩項：具體地說出限制、誠實地記錄失敗。它們不需要任何技術，只需要願意。

40.7 專題之後

40.7.1 三種去向

去向	需要什麼	注意	章節
交給真實使用者	維護者、SLA、事件流程	第 33 章的十六項檢查	第 33.8.2 節
作為研究的基礎	可重現、資料可用	第 16 章的紀律	第 16 章
開源給社群	授權、文件、範例	確認資料的授權	第 8.3 節
封存	完整的紀錄與說明	誠實記錄未完成的部分	本節

第四列不是失敗。一個誠實封存並完整記錄的專題，對後來的人仍有價值——它至少告訴他們「這條路試過，遇到了這些問題」。而那比一個誇大成果卻無法重現的專題有用得多。

40.7.2 交給真實使用者的門檻

第 33.8.2 節的十六項檢查在這裡是硬性的。特別要確認的五項：

- 有具名的維護者，且維護時間已納入規劃（第 33.7 節）。
- 涵蓋範圍已明確定義並會顯示給使用者（第 33.1.3 節）。
- 緊急停用機制已測試（第 33.8.2 節）。

- 殘餘風險已由適當層級接受（第 37.4.3 節）。
- 不依賴任何個人的帳號或憑證（第 33.7.4 節）。

第一項在學生專題中最常失敗：做的人畢業了，而沒有人接手。第 33.7 節說過那時候的正確選擇是誠實地說「這是研究原型，不提供服務」——而那個判斷應該在交出去之前就做出。

40.7.3 寫給後來的人

無論去向如何，建議留下一份簡短的文件給後來接觸這個題目的人。

NOTES_FOR_NEXT.md 的骨架

```
# 給下一個做這個題目的人

## 我們做了什麼
（三句話）

## 什麼有效
- （具體的做法與為什麼有效）

## 什麼無效
- （試過但失敗的做法，以及我們認為的原因）
- 這一節通常比上一節有價值

## 如果重來一次
- （會怎麼做不一樣）

## 沒有解決的問題
- （具體的，不要寫「效能有待改善」）

## 資料在哪、授權為何
- （含聯絡人）

## 三個建議
1. （最重要的一件事）
2.
3.
```

「什麼無效」那一節是這份文件最有價值的部分。論文與報告通常只寫成功的做法，而失敗的嘗試就消失了——結果每一屆的學生都重複踩同樣的坑。一份誠實記錄失敗的筆記，能省下後來者大量的時間。

40.8 回到第一章

40.8.1 那個問題

第 1 章開場時，一個國際模型自信地講錯了臺灣的升學制度——它用流暢的中文，講了一套不存在的

規則。

現在你知道那件事的每一個環節：

環節	為什麼會錯	怎麼修	章節
它不知道	訓練資料中沒有臺灣的制度	檢索或適配	第 28、30 章
它不會說不知道	訓練時沒有拒答的樣本	指令微調與對齊	第 23、25 章
它的用語漂移	繁中資料以其他地區為主	本土化適配	第 22 章
它很流暢	語言能力與知識是分離的	這正是危險所在	第 5 章
沒有人發現	沒有評測、沒有引用	評測與引用驗證	第 30、36 章

第四列是本書反覆強調的：流暢與正確是兩件事，而模型的流暢會讓錯誤更難被發現。從第 1 章到第 39 章，本書的許多設計——引用驗證、拒答測試、忠實度量測、幻覺測試——都是為了對抗這一件事。

40.8.2 四十章的主線

篇	主題	核心的一句話	章
第 1 篇	視野與基礎	先問要解決什麼，再問用什麼技術	1–4
第 2 篇	語言與語料	模型的能力來自資料，而資料需要工程	5–9
第 3 篇	從零實作	看得懂公式不等於寫得出來	10–13
第 4 篇	訓練與紀律	沒有實驗紀律的改善只是雜訊	14–17
第 5 篇	算力與系統	效能是算出來的，不是猜的	18–21
第 6 篇	本土化	在別人的模型上做出認識臺灣的東西	22–26
第 7 篇	推理與知識	能力固定，但使用方式能改變表現	27–30
第 8 篇	應用系統	從能不能做到，到該不該做	31–34

篇	主題	核心的一句話	章
第 9 篇	交付前的把關	跑得動、量得準、擋得住	35–37
第 10 篇	走出文字與總整	技術之外還有語言與人	38–40

如果要用一句話概括這四十章，那可能是：在資源有限的條件下，誠實地做出真的有用的東西。

「資源有限」是臺灣多數團隊的處境，而本書從第 17 章的算力預算到第 22 章的適配、第 24 章的 LoRA、第 26 章的邊緣部署，都在回答這個限制。

「誠實」則是本書最堅持的一件事——從第 8 章的資料清冊、第 16 章的實驗紀律、第 30 章的引用驗證、第 36 章的統計、到第 37 章的殘餘風險。它們的共同精神是：不宣稱超過證據所能支持的東西。

40.8.3 最後的話

本書從一個錯誤的答案開始，而在四十章之後，你手上有的不只是修好它的方法，更是一套判斷「什麼時候該修、什麼時候該說做不到」的能力。

技術會過時。本書提到的模型、框架、工具，在幾年之內多半會被取代。但幾件事不會：先量再改的紀律、誠實面對限制的態度、以及把使用者的真實處境放在技術之前的判斷。

而對臺灣而言，還有一件事值得記住：沒有人會替我們建立臺灣的語料、臺灣的評測、臺灣的知識庫。第 36 章說過，自建的臺灣制度知識天然未被污染，是本地評測的優勢所在——那個優勢只有在有人動手做的時候才會存在。

那件事，現在輪到你了。

附：全書速查索引

把四十章中最常被回頭查的計算與判準整理成一張表。

要算什麼	公式或判準	典型結果	章節
訓練的 FLOPs	$6 \times \text{參數量} \times \text{詞元數}$	7B、140B 詞元為 5.9 ZFLOPs	17.1
最適的資料量	約參數量的 20 倍	3B 需 60B 詞元	17.2
fertility	詞元數 $\div$ 字數	繁中約 1.4 至 2.3	7.5
KV cache	$2 \times T \times L \times H_{kv} \times d_{head} \times \text{bytes}$	T=4096 約 0.54 GB	14.5
訓練記憶體	參數量 $\times$ 16 bytes (混合精度)	7B 為 112 GB	18.4
LoRA 參數量	$r \times (d_{in} + d_{out}) \times \text{層數}$	7B r=16 約 40M	24.1
量化後的權重	參數量 $\times$ 位元數 $\div$ 8	3B INT4 為 1.5 GB	26.2
生成速度	有效頻寬 $\div$ 權重大小	3B INT4、600GB/s 為 240 tok/s	35.1
可接受的批次	總吞吐量 $\div$ 最低速度門檻	$240 \div 30 = 8$	35.1
多跳的成功率	單片段命中率的 n 次方	$0.85^3 = 0.614$	31.1
Agent 複合成功率	單步成功率的 n 次方	$0.9^{20} = 0.122$	32.1
重試後的單步	$1 - (1 - p)^k$	p=0.9、k=3 為 0.999	32.1
可接受的錯誤率	單次效益 $\div$ 單次錯誤損失	醫療約 0.5%	34.2
評測的可偵測差異	$1.96 \times \sqrt{(2p(1-p)/n)}$	n=100 約 0.12	36.1
所需的題數	依檢定力反推	偵測 3% 需 3,550 題	36.1
殘餘風險	原始風險 $\times$ (1 - 緩解效果)	$24\% \times 0.25 = 6\%$	37.4
影像詞元數	$(\text{邊長} \div \text{patch})^2$	336/14 為 576	38.1
語音詞元數	秒數 $\div$ 幀長	一分鐘 20ms 為 3,000	39.1

這張表的用途是速查，而每一項背後的推導與適用條件都在對應的章節。用公式之前先確認它的假設成立——那是本書從第 4 章就開始強調的紀律。

教師使用建議

本章是全書的最後一章，也是整學期專題的指引。建議在學期初就先講一次選題（40.1 節），讓學生有時間醞釀；學期中再回來講交付與評分。

時機	講什麼	互動設計	注意事項
學期第 1 至 2 週	40.1 節・選題	用十問檢查各組的初步構想	範圍過大要當場擋下
第 3 週	40.3 節・時程	各組排出自己的時程	資料建置要排在前面
第 8 至 10 週	40.4 節・交付清單	期中檢查	評測集是否開始
第 14 週	40.5 至 40.6 節・報告與評分	看一份範例報告	限制那一節是重點
第 18 週	40.7 至 40.8 節・展示與收尾	各組展示	要求含失敗案例

一個效果很好的做法：在期中檢查時特別確認「評測集開始了嗎」。40.3.3 節說過那是最致命的時程失誤，而在第 8 週介入還來得及。

關於展示：建議明訂「必須包含一個失敗案例」的要求。學生一開始會抗拒，但做過之後多數會發現——那個案例引發的討論，比成功的示範更有價值。

關於 40.8 節：這一節可以在最後一堂課朗讀或討論。它回到第 1 章的問題，也把四十章的主線收攏起來。對修完整學年課程的學生而言，那是一個值得留下的收尾。

高中授課的調整：高中的專題規模應設為 40.1.1 節的「小型」（約 60 小時），且建議聚焦在「知識系統」或「評測集」兩類——它們不需要 GPU，且能完整實踐本書的紀律。40.8 節的討論對高中生同樣適用，甚至更有啟發性。

本章小結

1. 總整專題不需要新技術——前三十九章已經足夠，本章提供整合的框架。
2. 選題的五個判準：範圍可完成、資料可取得、能被評測、有實際價值、風險可承受。
3. 如果想不出怎麼評測它，那就還不能開始做。
4. 第 34 章的十問中，若第 6、7、9 題答不出來，就先不要開始。
5. 前面各章的程式實作提供約 29 項可沿用的產出，專題是選擇與組合而非從零開始。

6. 中型專題約 135 小時：資料與評測占 35%，系統實作只占 19%。
7. 若八成的時間花在寫程式上，那配置就錯了。
8. 評測集必須在第 8 週前開始，否則沒有時間依據評測來改善。
9. 九項必要的交付中，第 1、5、8、9 項（定義、評測、交接、限制）不可減輕。
10. 評分中評測品質權重最高（25%），誠實與限制是獨立的加分項（15%）。
11. 六項不予計分的情況都不是「做得不夠好」，而是違反基本的研究誠信。
12. 展示應包含至少一個失敗案例——那讓其餘的宣稱更可信。
13. 對非技術聽眾，「每十次有一次需要查證」比「準確率 89.3%」有用。
14. 交給真實使用者需要通過第 33.8.2 節的十六項檢查，特別是維護者與緊急停用。
15. 誠實封存並完整記錄的專題不是失敗——它告訴後來者這條路遇到什麼問題。
16. 留給後來者的筆記中，「什麼無效」通常比「什麼有效」更有價值。
17. 第 1 章那個錯誤答案的五個環節，對應本書的五組方法。
18. 流暢與正確是兩件事，而模型的流暢會讓錯誤更難被發現。
19. 四十章的主線：在資源有限的條件下，誠實地做出真的有用的東西。
20. 沒有人會替我們建立臺灣的語料、評測與知識庫——那件事只有動手做才會存在。

成果檢核

完成總整專題後你必須繳交：

- 專題定義：範圍、明確不做什麼、成功的判準。
- 可運作的系統：他人能依文件跑起來。
- 資料或知識庫：含來源、授權、清冊。
- 評測集：至少 100 題，含分層與來源標記。
- 評測報告：區間、分層、污染檢查、失敗案例、caveats。
- 安全測試：紅隊報告，含未擋住的案例。
- 治理文件：風險矩陣、殘餘風險、揭露文字。
- 交接文件：經過他人試讀驗證。
- 限制說明：做不到什麼、為什麼。
- 給後來者的筆記：含「什麼無效」。

全書至此結束。

從第 1 章那個錯誤的答案，到現在你手上的這份專題——中間隔著四十章的公式、程式、實驗與判斷。但真正改變的可能不是你會的技術，而是你看待一個 AI 系統的方式：它會出錯、錯誤有代價、而工程的任務是讓那個代價可被承受、可被發現、可被說明。

那件事無論技術怎麼變，都不會過時。

索引

依詞條首字排序，數字為出現的章次。英文詞條排在中文詞條之前。索引依本冊內容編製；跨篇的完整索引見全書合訂本。

英文詞條

Agent 39、40
FLOPs 40
KV cache 40
LoRA 38、40
OCR 38、40
patch 38、40
RAG 38、40
tokenizer 39、40
Transformer 38、39、40

中文詞條

分散式訓練 40
分層架構 39
切片 38
幻覺 38、40
手寫 38
文白異讀 39
去傾斜 38
可重現 40
正規化 39
白話字 39
交付清單 40
印章 38
字元錯誤率 38、39
安全控制器 39
成果回饋 39
污染 38、40
自監督預訓練 39
位置資訊 38
低資源語言 39
技能標籤 39
投影層 38、39
罕用字 38
延遲預算 39
控制迴路 39
梅爾頻譜 39
混合策略 38
混合精度 38、40
視覺幻覺 38
視覺語言動作模型 39
視覺語言模型 38、39
視覺編碼器 38、39
速查索引 40
連續變調 39
給後來者的筆記 40
腔調 39
評分規準 40
評測 38、39、40
詞元 38、39、40
詞彙偏置 39
開放權重 40
微調 39、40
解析度 38
漢羅混寫 39
端到端 39、40
算力 40
管線式 39

注意力	38、39	緊急停止	39
物理限制	39	臺語	38、39
直書	38	臺羅	39
知情同意	39	語音編碼器	39
空白影像測試	38	影像詞元	38、40
前處理	38	模擬預檢	39
客語	38、39	線性投影	38
重取樣	38	遮蔽測試	38
限制說明	40	環境指紋	40
個資	38、39、40	縮圖	38
原住民族語	39	總整專題	38、40
動作詞元	39	繁體中文	38
參數量	40	離散語音單元	39

大模型導論 Introduction to Large Language Models

第 10 篇 多模態、具身智慧與總整專題 (第 38–40 章)

編著 李世淵 (機器人叫獸) | 助教 李天宇、李宇晴

課程與勘誤 : @prof (<https://page.line.me/prof>)

臺灣自編大學教科書系列 | 2026 年 8 月 第一版